


模式识别与机器学习

授课教师：杨卫东 胡静

L6-1



第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)



- 8.1 对偶支撑向量机动机 (*Motivation of Dual SVM*)
- 8.2 对偶支撑向量机的拉格朗日分析 (*Lagrange Dual SVM*)
- 8.3 求解对偶支撑向量机最佳值 (*Solving Dual SVM*)
- 8.4 对偶支撑向量机讨论 (*Messages behind Dual SVM*)
- 8.5 核函数支撑向量机 (*Kernel SVM*)


7.1 最大间隔分类面



“胖胖”的分类面



最大间隔分类面



所有样本正确分类




$$y_n = \text{sign}(\mathbf{w}^T \mathbf{x}_n)$$

$$\begin{aligned} \max_{\mathbf{w}} \quad & \text{margin}(\mathbf{w}) \\ \text{subject to} \quad & \text{every } y_n \mathbf{w}^T \mathbf{x}_n > 0 \\ & \text{margin}(\mathbf{w}) = \min_{n=1, \dots, N} \text{distance}(\mathbf{x}_n, \mathbf{w}) \end{aligned}$$

算法的目的是：如何找到“最大间隔”的分类面 (*find largest-margin separating hyperplane*)

8.1 对偶支撑向量机



线性支撑向量机模型

最佳的 $(\mathbf{w}, b) = ?$

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n (\mathbf{w}^T \mathbf{x}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

$$\textcircled{1} \quad \mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_d^T \\ \mathbf{0}_d & \mathbf{I}_d \end{bmatrix}, \quad \mathbf{p} = \mathbf{0}_{d+1},$$


$$\mathbf{a}_n^T = y_n [1 \quad \mathbf{x}_n^T], \quad c_n = 1,$$

$$\textcircled{2} \quad \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

③ 返回最终的 b 和 $\mathbf{w}$ 作为学到的 g_{SVM}

二次规划(QP, Quadratic Programming)

7.3 支撑向量机




利用二次规划(QP)实现支撑向量机

- ① $\mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_d^T \\ \mathbf{0}_d & \mathbf{I}_d \end{bmatrix}$, $\mathbf{p} = \mathbf{0}_{d+1}$, $\mathbf{a}_n^T = y_n[1 \quad \mathbf{x}_n^T]$, $c_n = 1$,
- ② $\begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$
- ③ 返回最终的 b 和 $\mathbf{w}$ 作为学到的 $\mathbf{g}_{\text{SVM}}$

线性硬间隔SVM算法(Linear Hard-Margin SVM Algorithm)

- Hard-Margin: 没有任何样本会落入到“胖胖的”间隔区域里!
- Linear: 样本 $\mathbf{x}_n$ 是线性可分的! 如果不是线性可分? $\mathbf{z}_n = \Phi(\mathbf{x}_n)$

8.1 对偶支撑向量机



非线性支撑向量机模型

最佳的 $(\mathbf{w}, b) = ?$

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n(\mathbf{w}^T \underbrace{\mathbf{z}_n}_{\Phi(\mathbf{x}_n)} + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

如果 $\tilde{d}$ 很大, 甚至无穷大, 挑战巨大

$$\textcircled{1} \quad \mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_{\tilde{d}}^T \\ \mathbf{0}_{\tilde{d}} & \mathbf{I}_{\tilde{d}} \end{bmatrix}, \quad \mathbf{p} = \mathbf{0}_{\tilde{d}+1},$$

$$\mathbf{a}_n^T = y_n[1 \quad \mathbf{x}_n^T], \quad c_n = 1,$$

$$\textcircled{2} \quad \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

③ 返回最终的 b 和 $\mathbf{w}$ 作为学到的 $\mathbf{g}_{\text{SVM}}$

QP针对 $(\tilde{d} + 1)$ 个变量和 N 个约束条件求解

目的: SVM算法求解可以不依赖于 $\tilde{d}$ 吗?

3.2 线性回归算法

线性回归算法

- 对训练样本集 $\mathcal{D}$ 构造输入特征向量矩阵 $\mathbf{X}$ 和输出向量 $\mathbf{Y}$

$$\mathbf{X} = \begin{bmatrix} - & -\mathbf{x}_1^T & - & - \\ - & -\mathbf{x}_2^T & - & - \\ & \vdots & & \\ - & -\mathbf{x}_N^T & - & - \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

- 计算广义逆: $\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$

- 计算回归值: $\mathbf{g} = \mathbf{w}^* = \mathbf{X}^\dagger \mathbf{Y}$

$$\mathbf{X}: N \times (d+1)$$

$$\mathbf{Y}: N \times 1$$

$$\mathbf{X}^\dagger: (d+1) \times N$$

$$\mathbf{w}: (d+1) \times 1$$

8.1 对偶支撑向量机

将有约束条件下的寻优转变为无约束条件下的寻优问题

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

用Lagrange乘子 α_n 构造Lagrange函数

$$\mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n + b))$$


约束项隐含在max中

$$\text{SVM} \equiv \min_{b, \mathbf{w}} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha}) \right) = \min_{b, \mathbf{w}} (\infty \text{ if violating, } \frac{1}{2} \mathbf{w}^T \mathbf{w} \text{ if feasible}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\bullet \text{ 任何 "violating" } (b, \mathbf{w}): \max_{\text{all } \alpha_n \geq 0} \left(\blacksquare + \sum_n \alpha_n (\text{一些正数}) \right) \rightarrow \infty$$

$$\bullet \text{ 任何 "feasible" } (b, \mathbf{w}): \max_{\text{all } \alpha_n \geq 0} \left(\blacksquare + \sum_n \alpha_n (\text{所有非正数}) \right) = \blacksquare$$

4.2 Fisher线性判别分析



二分类问题的Fisher线性判别:

学习最佳投影 $\mathbf{w}^*$ 的目标函数:

$$J(\mathbf{w}) = \frac{\text{between class scatter}}{\text{within class scatter}}$$

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmax}} J(\mathbf{w})$$

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

最大化目标函数问题转化为:

$$\max_{\mathbf{w}} \mathbf{w}^T \mathbf{S}_B \mathbf{w} \quad \text{Subject to } \mathbf{w}^T \mathbf{S}_w \mathbf{w} = K$$

利用拉格朗日乘子法 (Lagrange multipliers) :


$$L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_B \mathbf{w} + \lambda(K - \mathbf{w}^T \mathbf{S}_w \mathbf{w})$$

$$= \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w} + \lambda K$$

$$\nabla L_w(\mathbf{w}, \lambda) = \frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \mathbf{0}^T$$

$$2(\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w} = \mathbf{0} \Rightarrow \mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

第八讲 对偶支撑向量机与核支撑向量机 (Dual SVM & Kernel SVM)



8.1 对偶支撑向量机动机 (Motivation of Dual SVM)

8.2 对偶支撑向量机的拉格朗日分析 (Lagrange Dual SVM)

8.3 求解对偶支撑向量机最佳值 (Solving Dual SVM)

8.4 对偶支撑向量机讨论 (Messages behind Dual SVM)

8.5 核函数支撑向量机 (Kernel SVM)

8.2 对偶支撑向量机的拉格朗日分析



在所有的 $\alpha_n \geq 0$ 的中挑选任意一个 α' ($\because \max \geq \text{any}$)

$$\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \min_{b,w} (\mathcal{L}(b, w, \alpha'))$$


如果 $\alpha' \geq 0$ 是上式右边 $\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha)$ 中的最佳值 ($\because \text{best is one of any}$)

$$\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \underbrace{\max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} (\mathcal{L}(b, w, \alpha')) \right)}_{\text{Lagrange Dual Problem}}$$

Primal Problem 原问题 Lagrange Dual Problem 拉格朗日对偶问题

原问题 (求解 b, w) 与 拉格朗日对偶问题 (求解 α) 的关系

8.2 对偶支撑向量机的拉格朗日分析



二次规划(QP)满足强对偶特性

$$\underbrace{\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right)}_{\substack{\text{equiv.to original SVM} \\ \text{Primal Problem (原问题)}}} \geq \underbrace{\max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} (\mathcal{L}(b, w, \alpha)) \right)}_{\substack{\text{Lagrange Dual Problem} \\ \text{(对偶问题)}}$$

- “ $\geq$ ”是一种弱对偶关系(weak duality)
- “=”是一种强对偶关系(strong duality), 如果满足:

二次规划(QP)问题



- 原问题是凸函数
- 原问题存在可行解
- 约束条件为线性的

非线性变换 $\Phi(\mathbf{x}_n)$

8.2 对偶支撑向量机的拉格朗日分析

二次规划(QP)满足强对偶特性

$$\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) = \max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} (\mathcal{L}(b, w, \alpha)) \right)$$

equiv.to original SVM Primal Problem
Lagrange Dual Problem

等式两边对原问题求解和对对偶问题求解都能得到最优 (b, w, α)

- “ $\geq$ ”是一种弱对偶关系(weak duality)
- “ $=$ ”是一种强对偶关系(strong duality), 如果满足:

二次规划(QP)问题

- 原问题是凸函数
- 原问题存在可行解
- 约束条件为线性的

非线性变换 $\phi(\mathbf{x}_n)$

8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} \underbrace{\left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n + b)) \right)}_{\mathcal{L}(b, w, \alpha)} \right)$$

- “括号”内的问题(inner problem)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial b} = - \sum_{n=1}^N \alpha_n y_n = 0$$



$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b,w} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) - \sum_{n=1}^N \alpha_n y_n b \right) \right)$$

8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0} \left(\min_{b, \mathbf{w}} \underbrace{\left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n + b)) \right)}_{\mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})} \right)$$

- “括号”内的问题(inner problem)是**无约束条件**的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial b} = - \sum_{n=1}^N \alpha_n y_n = 0$$

“括号”内的问题**b**取最佳解时：

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

- “括号”内的问题(inner problem)是**无约束条件**的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题**w**取最佳解时：

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n - \mathbf{w}^T \mathbf{w} \right) \right)$$

8.2 对偶支撑向量机的拉格朗日分析



对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$


- “括号”内的问题(inner problem)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \longrightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题 $\mathbf{w}$ 取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(\min_{b, \mathbf{w}} \left(-\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n \right) \right)$$

8.2 对偶支撑向量机的拉格朗日分析



对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

- “括号”内的问题(inner problem)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \longrightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题 $\mathbf{w}$ 取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$

8.2 对偶支撑向量机的拉格朗日分析

KKT条件

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$

如果 $(b, \mathbf{w}, \alpha)$ 是原问题-对偶问题的最佳解(*primal-dual optimal*):

- 原问题可行解(*primal feasible*): $y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1$
- 对偶问题可行解(*dual feasible*): $\alpha_n \geq 0$
- 对偶“括号”内优化解(*dual-inner optimal*): $\sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$
- 原问题“括号”内优化解(*primal-inner optimal*): $\alpha_n(1 - y_n(\mathbf{w}^T \mathbf{z}_n + b)) = 0$

---称为KKT条件, 为优化的充要条件

利用对偶问题求解最佳 α 后, 再用KKT条件得到 $(b, \mathbf{w})$

KKT条件

KKT条件将Lagrange乘子法所处理涉及等式的约束优化问题推广至不等式

- 1) 是拉格朗日取得可行解的必要条件;
- 2) 引入乘子 β_j , 去掉不等式, 称作松弛互补条件;
- 3)、4) 初始约束条件;
- 5) 不等式约束的 Lagrange Multiplier 需满足的条件

$$\min f(x), s.t. h_i(x) = 0, i = 1, 2, \dots, m; g_j(x) \leq 0, j = 1, 2, \dots, n$$

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^m \alpha_i h_i(x) + \sum_{j=1}^n \beta_j g_j(x)$$

$$\nabla_x L(x, \alpha, \beta) = 0 \quad (1)$$


$$\beta_j g_j(x) = 0, j = 1, 2, \dots, n \quad (2)$$

$$h_i(x) = 0, i = 1, 2, \dots, m \quad (3)$$

$$g_j(x) \leq 0, j = 1, 2, \dots, n \quad (4)$$


$$\beta_j \geq 0, j = 1, 2, \dots, n \quad (5)$$

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)



- 8.1 对偶支撑向量机动机(Motivation of Dual SVM)
- 8.2 对偶支撑向量机的拉格朗日分析(Lagrange Dual SVM)
- 8.3 求解对偶支撑向量机最佳值(Solving Dual SVM)
- 8.4 对偶支撑向量机讨论(Messages behind Dual SVM)
- 8.5 核函数支撑向量机(Kernel SVM)

8.3 求解对偶支撑向量机最佳值



支撑向量机的对偶问题求解

$$\max_{\alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$

标准的硬间隔SVM的对偶问题----求解最佳 α :

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

- α 的目标函数是二次函数、凸函数! N 个变量
- α 的约束条件是线性函数! $N+1$ 个约束条件

----二次规划(QP)问题!

QP有成熟方便的办法求优化解!

8.3 求解对偶支撑向量机最佳值

SVM对偶问题的一般求解:

最佳的 $\alpha = ?$

$$\min_{\alpha} \quad \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n$$

Subject to $\sum_{n=1}^N \alpha_n y_n = 0$

$\alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N$

$\mathbf{u} = [\alpha_1 \quad \dots \quad \alpha_n \quad \dots \quad \alpha_N]^T$

$\mathbf{p} = -\mathbf{1}_N$

$$\mathbf{Q} = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \dots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & y_n y_m \mathbf{z}_n^T \mathbf{z}_m & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \dots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}$$

二次规划(QP)的求解:

最佳的 $\mathbf{u} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

$$\min_{\mathbf{u}} \quad \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u}$$

Subject to $\mathbf{a}_m^T \mathbf{u} \geq c_m$
for $m = 1, 2, \dots, M$

$\mathbf{a}_{\geq}^T = [y_1 \quad \dots \quad y_n \quad \dots \quad y_N], \quad c_{\geq} = 0$

$\mathbf{a}_{\leq}^T = [-y_1 \quad \dots \quad -y_n \quad \dots \quad -y_N], \quad c_{\leq} = 0$

$\mathbf{a}_1^T = [1 \quad \dots \quad 0 \quad \dots \quad 0],$

$\mathbf{a}_n^T = [0 \quad \dots \quad 1 \quad \dots \quad 0], \quad c_n = 0, \quad M = N$

$\mathbf{a}_N^T = [0 \quad \dots \quad 0 \quad \dots \quad 1],$

8.3 求解对偶支撑向量机最佳值

利用二次规划(QP)实现支撑向量机对偶问题求解

① $\mathbf{Q} = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \dots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & y_n y_m \mathbf{z}_n^T \mathbf{z}_m & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \dots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}, \quad \mathbf{p} = -\mathbf{1}_N,$

$\mathbf{a}_n^T = [0 \quad \dots \quad 1 \quad \dots \quad 0], \quad c_n = 0,$


$\mathbf{a}_{\geq}^T = [y_1 \quad \dots \quad y_n \quad \dots \quad y_N], \quad c_{\geq} = 0,$

$\mathbf{a}_{\leq}^T = [-y_1 \quad \dots \quad -y_n \quad \dots \quad -y_N], \quad c_{\leq} = 0,$

② $[\alpha_1 \quad \dots \quad \alpha_n \quad \dots \quad \alpha_N]^T \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

③ 返回最终的 α

8.3 求解对偶支撑向量机最佳值



求解最佳的 (b, w)


如果 (b, w, α) 是原问题-对偶问题的最佳解(*primal-dual optimal*):

- 原问题可行解(*primal feasible*): $y_n(w^T z_n + b) \geq 1$
- 对偶问题可行解(*dual feasible*): $\alpha_n \geq 0$
- 对偶“括号”内优化解(*dual-inner optimal*): $\sum_{n=1}^N \alpha_n y_n = 0, w = \sum_{n=1}^N \alpha_n y_n z_n$
- 原问题“括号”内优化解(*primal-inner optimal*): $\alpha_n (1 - y_n(w^T z_n + b)) = 0$

----称为KKT条件, 为优化的充要条件

挑选任意一个 $\alpha_n > 0$ 的样本, $b = y_n - w^T z_n$ $\alpha_n > 0$ 的样本是支撑向量


第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)



- 8.1 对偶支撑向量机动机 (*Motivation of Dual SVM*)
- 8.2 对偶支撑向量机的拉格朗日分析 (*Lagrange Dual SVM*)
- 8.3 求解对偶支撑向量机最佳值 (*Solving Dual SVM*)
- 8.4 对偶支撑向量机讨论 (*Messages behind Dual SVM*)
- 8.5 核函数支撑向量机 (*Kernel SVM*)

7.3 支撑向量机

为什么叫支撑向量机?



$$\mathbf{X} = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$$

$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\text{Subject to} \quad y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1, \text{ for all } n$$

优化得到的解为:

$$w_1 = 1, w_2 = -1, b = -1$$

$$g(\mathbf{x}) = \text{sign}(x_1 - x_2 - 1)$$

$$\text{margin}(\mathbf{w}) = \frac{1}{\|\mathbf{w}\|} = \frac{1}{\sqrt{2}}$$

- 分类面由边界上的样本确定, 其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

支撑向量机(SVM)—Support Vector Machine
----借助支撑向量学到间隔最大分类面

8.4 对偶支撑向量机讨论

SVM原问题


- 分类面由边界上的样本确定, 其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

SVM对偶问题

- $\alpha_n > 0$ 的样本落在分类面的边界上
 - $\alpha_n > 0$ 的样本 $(\mathbf{z}_n, y_n)$ 被称为支撑向量(候选)
- $$SV(\alpha_n > 0 \text{ 的样本}) \subseteq SV(\text{边界上的样本})$$

求解 $\mathbf{w}$ 时, 只需要支撑向量: $\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$

求解 b 时, 只需要任一个支撑向量 $(\mathbf{z}_n, y_n)$: $b = y_n - \mathbf{w}^T \mathbf{z}_n$



SVM

----利用对偶问题的最佳解确定支撑向量, 从而找到间隔最大的分类面

8.4 对偶支撑向量机讨论



SVM:

$$\mathbf{w}_{SVM} = \sum_{n=1}^N \alpha_n (\mathbf{y}_n \mathbf{z}_n)$$

α_n 由对偶问题的解确定

$\mathbf{w}$ 是 $\mathbf{y}_n \mathbf{z}_n$ 的线性组合

$\mathbf{w}$ 被数据 $\mathbf{y}_n \mathbf{z}_n$ 所表达

$\mathbf{w}$ 体现出“模式”

SVM: 仅通过SV表达 $\mathbf{w}$


PLA:

$$\mathbf{w}_{PLA} = \sum_{n=1}^N \beta_n (\mathbf{y}_n \mathbf{z}_n)$$

β_n 由分错的样本确定



8.4 对偶支撑向量机讨论



SVM的原问题求解:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & \mathbf{y}_n (\mathbf{w}^T \mathbf{z}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

- $(d+1)$ 个变量和 N 个约束条件
- 求解最佳 $(b, \mathbf{w})$


SVM的对偶问题求解:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m \mathbf{y}_n \mathbf{y}_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n \mathbf{y}_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

- N 个变量和 $N+1$ 个约束条件
- 求解最佳 α , 确定支撑向量


两种方法都能得到最佳解 $(b, \mathbf{w})$ 获得最大间隔分类面 $g_{SVM} = \text{sign}(\mathbf{w}^T \phi(\mathbf{x}_n) + b)$

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)



- 8.1 对偶支撑向量机动机 (*Motivation of Dual SVM*)
- 8.2 对偶支撑向量机的拉格朗日分析 (*Lagrange Dual SVM*)
- 8.3 求解对偶支撑向量机最佳值 (*Solving Dual SVM*)
- 8.4 对偶支撑向量机讨论 (*Messages behind Dual SVM*)
- 8.5 核函数支撑向量机 (*Kernel SVM*)

8.5 核函数支撑向量机



研究对偶SVM的动机是**不想依赖** $\tilde{d}$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

8.5 核函数支撑向量机

研究对偶SVM的动机是**不想依赖 $\tilde{d}$**

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^T Q \alpha - \mathbf{1}^T \alpha \\ \text{Subject to} \quad & \mathbf{y}^T \alpha = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

$$Q = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \cdots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & y_n y_m \mathbf{z}_n^T \mathbf{z}_m & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \cdots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}$$

对偶SVM真的不依赖于 $\tilde{d}$?

- N 个变量和 $N+1$ 个约束条件
- 对偶问题的 Q 是个稠密矩阵
- 每个元素 $q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m$ 都要做**内积运算**, 计算代价 $O(\tilde{d})$

能提高 $\mathbf{z}_n^T \mathbf{z}_m = \Phi(\mathbf{x}_n)^T \Phi(\mathbf{x}_m)$ 计算效率吗?

8.5 核函数支撑向量机

二次多项式 $\Phi_2(\mathbf{x})$ 的快速内积计算

$$\Phi_2(\mathbf{x}) = (1, x_1, x_2, \dots, x_d, x_1^2, x_1 x_2, \dots, x_1 x_d, x_2 x_1, x_2^2, \dots, x_2 x_d, x_d x_1, x_d x_2, \dots, x_d^2)$$

$$\begin{aligned} \Phi_2^T(\mathbf{x}) \Phi_2(\mathbf{x}') &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d \sum_{j=1}^d x_i x_j x'_i x'_j \\ &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d x_i x'_i \sum_{j=1}^d x_j x'_j \\ &= 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}') (\mathbf{x}^T \mathbf{x}') \end{aligned}$$

$$(\mathbf{x}^T \mathbf{x}')$$

计算复杂度从 $O(\tilde{d})$ 下降到 $O(d)$

8.5 核函数支撑向量机

核函数： Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

支撑SV $(\mathbf{z}_m, y_m)$: $b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \left(\sum_{SV} \alpha_n y_n \mathbf{z}_n \right)^T \mathbf{z}_m$

输入测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数： Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$


$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

支撑SV $(\mathbf{z}_m, y_m)$: $b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m)$

输入测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b)$

8.5 核函数支撑向量机



核函数： Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$


$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

支撑SV $(\mathbf{z}_m, y_m)$: $b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$

输入测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}((\sum_{SV} \alpha_n y_n \mathbf{z}_n)^T \Phi(\mathbf{x}) + b)$

8.5 核函数支撑向量机



核函数： Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

支撑SV $(\mathbf{z}_m, y_m)$: $b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$

输入测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}(\sum_{SV} \alpha_n y_n \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数: Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

支撑SV $(\mathbf{z}_m, y_m)$: $b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$

输入测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}(\sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}) + b)$

利用核函数, 将
计算复杂度从
 $O(\tilde{d})$ 下降到 $O(d)$
避免依赖 $\tilde{d}$


8.5 核函数支撑向量机

利用二次规划(QP)实现核函数支撑向量机求解

- ① $q_{n,m} = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$, $\mathbf{p} = -\mathbf{1}_N$, 由约束条件得到 $(\mathbf{A}, \mathbf{c})$
- ② $\alpha \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$
- ③ 任选一支撑SV $(\mathbf{x}_m, y_m)$: $b \leftarrow (y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m))$
- ④ 对于测试样本 $\mathbf{x}$: $g_{SVM} = \text{sign}(\sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}) + b)$

- 步骤①的时间复杂度: $O(N^2) \cdot (\text{kernel evaluation})$
- 步骤②的开销: N 个变量, $N + 1$ 个约束
- 步骤③和④的复杂度: $O(\#SV) \cdot (\text{kernel evaluation})$

8.5 核函数支撑向量机



二次多项式核函数的一般表达式


$\Phi_2(\mathbf{x})$	$K_2(\mathbf{x}, \mathbf{x}')$
$(1, x_1, \dots, x_d, x_1^2, x_1x_2, \dots, x_d^2)$	$1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$
$(1, \sqrt{2}x_1, \dots, \sqrt{2}x_d, x_1^2, x_1x_2, \dots, x_d^2)$	$1 + 2\mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$
$(1, \sqrt{2\gamma}x_1, \dots, \sqrt{2\gamma}x_d, x_1^2, x_1x_2, \dots, x_d^2)$	$1 + 2\gamma\mathbf{x}^T \mathbf{x}' + \gamma^2(\mathbf{x}^T \mathbf{x}')^2$

$$K_2(\mathbf{x}, \mathbf{x}') = (1 + \gamma\mathbf{x}^T \mathbf{x}')^2 \quad \gamma > 0$$


不同的二次多项式变换：

- 升维次数相同
- 内积结果不同 → 分类面不同

8.5 核函数支撑向量机



二次多项式核函数的一般表达式



- 核函数不同 → 支撑向量(SVs)不同，分类面(g_{SVM})不同
- 核函数变化 → Margin也会变化

8.5 核函数支撑向量机

多项式核函数的一般表达式


$$K_2(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^2 \quad \gamma > 0, \zeta \geq 0$$

$$K_3(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^3 \quad \gamma > 0, \zeta \geq 0$$

⋮

$$K_Q(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^Q \quad \gamma > 0, \zeta \geq 0$$

- Q 、 γ 、 ζ 确定了多项式核函数的形式
- 利用核函数可不依赖于 $\tilde{d}$ 获得大间隔分类面



Margin为1的10次多项式

SVM + Polynomial Kernel
= Polynomial SVM

8.5 核函数支撑向量机

核函数能实现无穷维变换?

当 $\Phi(\mathbf{x})$ 为无穷维变换时, 借助核函数 $K(\mathbf{x}, \mathbf{x}')$ 技巧仍可进行有效计算
为简单起见, 考虑一维变量, 即: $\mathbf{x} = (x)$

$$\begin{aligned} K(x, x') &= \exp(-(x - x')^2) = \exp(-(x)^2) \exp(-(x')^2) \exp(2xx') \\ &= \exp(-(x)^2) \exp(-(x')^2) \left(\sum_{i=0}^{\infty} \frac{(2xx')^i}{i!} \right) \\ &= \sum_{i=0}^{\infty} (\exp(-(x)^2) \exp(-(x')^2) \sqrt{\frac{2^i}{i!}} \sqrt{\frac{2^i}{i!}} (x)^i (x')^i) \\ \Phi(x) &= \exp(-(x)^2) \cdot (1, \sqrt{\frac{2^1}{1!}} x, \sqrt{\frac{2^2}{2!}} x^2, \sqrt{\frac{2^3}{3!}} x^3, \dots, \dots) \end{aligned}$$

8.5 核函数支撑向量机

核函数能实现无穷维变换?

当 $\Phi(\mathbf{x})$ 为无穷维变换时, 借助核函数 $K(\mathbf{x}, \mathbf{x}')$ 技巧仍可进行有效计算
为简单起见, 考虑一维变量, 即: $\mathbf{x} = (x)$

$$\begin{aligned} K(x, x') &= \Phi(x)^T \Phi(x') = \exp(-(x - x')^2) = \exp(-(x)^2) \exp(-(x')^2) \exp(2xx') \\ &= \exp(-(x)^2) \exp(-(x')^2) \left(\sum_{i=0}^{\infty} \frac{(2xx')^i}{i!} \right) \end{aligned}$$

高斯核函数 $K(\mathbf{x}, \mathbf{x}')$ 的一般式

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \quad \gamma > 0$$

$$= \sum_{i=0}^{\infty} (\exp(-(x)^2) \exp(-(x')^2) \sqrt{\frac{2^i}{i!}} \sqrt{\frac{2^i}{i!}} (x)^i (x')^i)$$

$$\Phi(x) = \exp(-(x)^2) \cdot (1, \sqrt{\frac{2^1}{1!}}x, \sqrt{\frac{2^2}{2!}}x^2, \sqrt{\frac{2^3}{3!}}x^3, \dots, \dots)$$

8.5 核函数支撑向量机

高斯核函数SVM


$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \quad \gamma > 0$$

$$\begin{aligned} \text{输入测试样本 } \mathbf{x}: \quad g_{SVM} &= \text{sign} \left(\sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}) + b \right) \\ &= \text{sign} \left(\sum_{SV} \alpha_n y_n \exp(-\gamma \|\mathbf{x} - \mathbf{x}_n\|^2) + b \right) \end{aligned}$$

- 以所有支撑向量 $\mathbf{x}_n$ 为中心的高斯函数的线性组合
- 也被称之为径向基核函数(Radial Basis Function, RBF)

高斯核函数SVM: 通过求取 α_n 确定所有支撑向量 $\mathbf{x}_n$, 构造以支撑向量为中心的高斯函数的线性组合, 实现在无穷维空间获得最大间隔分类面

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)



8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

希望不依赖于非线性变换后升维的 $\tilde{d}$

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

通过 **KKT** 条件 将原问题和对偶问题相关联获得最佳分类面

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

仍然是二次规划问题，可以方便求解

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

由支撑向量确定最大间隔分类面

8.5 核函数支撑向量机(*Kernel SVM*)

利用核函数避免了对升维后 $\tilde{d}$ 的依赖，且高效求解