

§ 16 特征选择

16.1 特征选择的判据作用是什么？判据构造的原则是什么？请列举有哪些不同类型的判据，并简单说明至少三种特征选择方法。

参考答案

答：

判据的作用：数学上定义的用以衡量特征对分类的效果的准则，用于找出一组对分类最好的特征。

原则：（1）与错误率有单调关系

（2）判据具有“距离”的某些特性。

（3）对独立的特征有可加性。

（4）增加特征时判据不减小。

常用的判据：（1）基于类内类间距离的可分性判据

（2）基于概率分布的可分性判据

（3）基于熵的可分性判据

（4）利用统计检验作为可分性判据

特征选择方法（1）单独最优组合：选取前 d 个单独最优特征

（2）SFS 法：从底向上。每加入一个特征寻优一次，使加入该特征后的特征集合判据最大

$$J(X_k + x_1) \geq J(X_k + x_2) \geq \cdots \geq J(X_k + x_{n-k})$$

特点：考虑了特征间的相关性，但某特征一经入选，则无法淘汰。

（3）SBS 法：从顶向下，每次减一个特征，与 SFS 相对，一旦失去，无法换回。

$$J(\bar{X}_k - x_1) \geq J(\bar{X}_k - x_2) \geq \cdots \geq J(\bar{X}_k - x_{n-k})$$

§ 17 特征提取

17.1 已知两类样本,

ω_1 : $\{(-1, -4)^T, (-1, -5)^T, (0, -4)^T, (0, -5)^T\}$ 。

ω_2 : $\{(0, 4)^T, (0, 5)^T, (1, 4)^T, (1, 5)^T\}$, 试用 PCA 变化做一维特征提取, 给出新的一维特征值

答: $P(\omega_1) = P(\omega_2) = 0.5$,

$$R = E(XX^T) = \frac{1}{8} \left[\begin{pmatrix} 1 & 4 \\ 4 & 16 \end{pmatrix} + \begin{pmatrix} 1 & 5 \\ 5 & 25 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 16 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 25 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 16 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 25 \end{pmatrix} + \begin{pmatrix} 1 & 4 \\ 4 & 16 \end{pmatrix} + \begin{pmatrix} 1 & 5 \\ 5 & 25 \end{pmatrix} \right] = \begin{pmatrix} 0.5 & 2.25 \\ 2.25 & 20.5 \end{pmatrix}$$

令 $|R - \lambda I| = 0$, 得 $\lambda_1 = 20.75$, $\lambda_2 = 0.25$, 对应 $u_1 = \frac{1}{\sqrt{82}} \begin{pmatrix} 1 \\ 9 \end{pmatrix}$, $u_2 = \frac{1}{\sqrt{82}} \begin{pmatrix} 9 \\ -1 \end{pmatrix}$

所以选择 $\lambda_1 = 20.75$ 对应的向量 $u_1 = \frac{1}{\sqrt{82}} \begin{pmatrix} 1 \\ 9 \end{pmatrix}$ 作为转换矩阵。

变换后的一维样本特征为:

$$\omega_1: \left\{ \frac{-37}{\sqrt{82}}, \frac{-46}{\sqrt{82}}, \frac{-36}{\sqrt{82}}, \frac{-45}{\sqrt{82}} \right\}, \quad \omega_2: \left\{ \frac{36}{\sqrt{82}}, \frac{45}{\sqrt{82}}, \frac{37}{\sqrt{82}}, \frac{46}{\sqrt{82}} \right\}$$

17.2 对于一个已经训练好的基于 PCA 算法的人脸图像压缩系统，如果输入的是如下这一张图像，




那么解压缩后输出的结果是怎样的？为什么？

参考答案

答：

很多张人脸混合后的结果，模糊，看不清。

因为 PCA 提取出的特征脸是基于人脸图像获得的结果，其输出图像是多个特征脸的线性组合，但是输入的企鹅图像并不是人脸，提取的特征点在特征空间中是远离人脸样本类的。如下图所示：



但输出图像依然只能用多个特征脸的线性组合表示，非人脸的元素在 PCA 变换过程中被降维过程丢弃，企鹅的非人脸细节消失。但企鹅图像的人脸细节由不充分，因此在 PCA 后的特征空间各个维度都没有显著的取值，因此就只能是多张特征脸混合后的结果，特征脸本就是模糊的多张人脸的元素的线性叠加结果，所以最后输出是很多张人脸混合后的结果，模糊，看不清。

§ 18 聚类分析 (k 均值)

18.1 将如下的 8 个样本点 (用 (i, j) 代表位置) 用 k 均值聚类算法分为三个簇, $x_1(2, 10)$, $x_2(2, 5)$, $x_3(8, 4)$, $x_4(5, 8)$, $x_5(7, 5)$, $x_6(6, 4)$, $x_7(1, 2)$, $x_8(4, 9)$ 距离函数是欧几里得距离, 假设初始我们选择 x_1 , x_4 和 x_7 分别为每个簇的中心, 用 k 均值算法给出最后的三个簇是什么?

答:

1) 第一步选择 x_1 , x_4 , x_7 为聚类中心, 可以计算出:

$$S_1(1) = \{x_1\}$$

$$S_2(1) = \{x_4, x_3, x_5, x_6, x_8\}$$

$$S_3(1) = \{x_2, x_7\}$$

计算新的聚类中心:

$$Z_1(1) = (2, 10)$$

$$Z_2(1) = (6, 6)$$

$$Z_3(1) = \left(\frac{3}{2}, \frac{7}{2}\right)$$

2) 选择新的聚类中心, 可以计算出:

$$S_1(2) = \{x_1, x_8\}$$

$$S_2(2) = \{x_4, x_3, x_5, x_6\}$$

$$S_3(2) = \{x_2, x_7\}$$

计算新的聚类中心:

$$Z_1(2) = (3, 19/2)$$

$$Z_2(2) = (13/2, 21/4)$$

$$Z_3(2) = \left(\frac{3}{2}, \frac{7}{2}\right)$$

3) 选择新的聚类中心, 可以计算出:

$$S_1(3) = \{x_1, x_4, x_8\}$$

$$S_2(3) = \{x_3, x_5, x_6\}$$

$$S_3(3) = \{x_2, x_7\}$$

计算新的聚类中心:

$$Z_1(3) = (1 \ 1 / 3, \ 9)$$

$$Z_2(3) = (7, \ 1 \ 3 / 3)$$

$$Z_3(3) = (\frac{3}{2}, \ \frac{7}{2})$$

4) 选择新的聚类中心, 可以计算出:

$$S_1(4) = \{x_1, x_4, x_8\}$$

$$S_2(4) = \{x_3, x_5, x_6\}$$

$$S_3(4) = \{x_2, x_7\}$$

计算新的聚类中心:

$$Z_1(4) = (1 \ 1 / 3, \ 9)$$

$$Z_2(4) = (7, \ 1 \ 3 / 3)$$

$$Z_3(4) = (\frac{3}{2}, \ \frac{7}{2})$$

聚类中心与第三步相同, 所以迭代结束, 聚类结果为

$$S_1 = \{x_1, x_4, x_8\}$$

$$S_2 = \{x_3, x_5, x_6\}$$

$$S_3 = \{x_2, x_7\}$$