
Lecture1 作业

1, 现在很多火车站都可以持身份证和车票“刷脸”进站, 张同学拿着自己的身份证进站时机器却识别错误, 从模式识别的角度看机器难以识别他的原因是:

- (a) 不存在模式;
- (b) 没有训练样本;
- (c) 不同类的模式相似度高;
- (d) 同一类的模式差异性大。

2, 某研究人员用带有标签的数据库训练其目标识别算法, 希望用在自动驾驶中对路况进行场景理解和行人检测, 请问这个算法需要去解决哪种类型的学习问题:

- (a) 监督学习;
- (b) 无监督学习;
- (c) 半监督学习;
- (d) 增强学习。

3, 如果一个好的学习算法通过训练样本集在解空间(假设空间)集合中找到一个最优解, 使得其对所有训练样本都能够实现正确的模式识别, 以下哪种说法正确:

- (a) 目标函数是已知的;
- (b) 所有训练样本都是线性可分的;
- (c) 训练样本集上全部分类正确, 不能代表测试时也能正确;
- (d) 好的学习算法能够容许训练样本存在错误的标签。

4, 某个电影网站每名网络用户都可以给电影打分, 用户有 id 号, 电影也有 id 号, 网站已积累了 10 万个用户对所看电影喜爱程度的打分, 并将电影的特征如喜剧片、动作片、爱情片、...、明星甲、明星乙等与观众对这些特征的喜好匹配组合到一起设计了推荐系统, 给每部电影一个百分制的评分结果。请用上述这些元素去构造一个学习问题。

解:

$$S_1 = [0, 100]$$

$$S_2 = \text{所有由用户 id 号和电影 id 号组成的向量: } [userid, movied]$$

$$S_3 = \text{某种数学模型, 将电影的特征如喜剧片、动作片、爱情片、...、明星甲、明星乙等与观众对这些特征的喜好匹配组合到一起打分}$$

$$S_4 = 10 \text{ 万个用户对他们所看过电影喜爱程度的一一评价结果:}$$

$$[(userid, movied), rating]$$

$$\text{学习问题: } S_1 = Y, S_2 = X, S_3 = H, S_4 = D$$

5, 有一数据集共有 2000 张花卉图片, 其中 1400 张是玫瑰, 300 张是月季, 300 张是蔷薇。某同学设计了一个玫瑰识别算法, 从 2000 张图片中识别出 1000 张图片为玫瑰, 但实际上其中只有 600 张是玫瑰, 另外 300 张是月季、100 张是蔷薇。请计算分类正确率 (Accuracy)、分类错误率 (Error rate)、分类精度 (Precision)、召回率 (Recall)、F1 分数 (F1 Score)。如果该同学的算法把 2000 张图片都识别成玫瑰, 请再次计算出上述指标。

解: (1) 混淆矩阵为:

		预测结果	
		正 1000	负 1000
真 实 结果	正 1400	TP 600	FN 800
	负 600	FP 400	TN 200

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} = \frac{600 + 200}{2000} = 40\%$$

$$Error = 1 - Accuracy = 1 - 40\% = 60\%$$

$$Precision = \frac{TP}{TP + FP} = \frac{600}{600 + 400} = 60\%$$

$$Recall = \frac{TP}{TP + FN} = \frac{600}{600 + 800} = 43\%$$

$$F1\ Score = \frac{2 * Precision * Recall}{Precision + Recall} = \frac{2 * 0.6 * 0.43}{0.6 + 0.43} = 0.5$$

(2) 混淆矩阵为:

		预测结果	
		正 2000	负 0
真 实 结果	正 1400	TP 1400	FN 0
	负 600	FP 600	TN 0

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} = \frac{1400 + 0}{2000} = 70\%$$

$$Error = 1 - Accuracy = 1 - 70\% = 30\%$$

$$Precision = \frac{TP}{TP + FP} = \frac{1400}{1400 + 600} = 70\%$$

$$Recall = \frac{TP}{TP + FN} = \frac{1400}{1400 + 0} = 100\%$$

$$F1\ Score = \frac{2 * Precision * Recall}{Precision + Recall} = \frac{2 * 0.7 * 1}{0.7 + 1} = 0.82$$

Lecture2 作业

1, 假设训练样本集为 $D = \{(\mathbf{x}_1, y_1) = ((3,3)^T, 1), (\mathbf{x}_2, y_2) = ((4,3)^T, 1), (\mathbf{x}_3, y_3) = ((1,1)^T, -1)\}$, 使用感知器算法设计分类面, 并判断测试样本 $\mathbf{x} = (0,1)^T$ 属于哪个类别。

解:

样本增广后为: $\vec{x}_1 = (1,3,3)^T$, $y_1 = 1$, $\vec{x}_2 = (1,4,3)^T$, $y_2 = 1$, $\vec{x}_3 = (1,1,1)^T$, $y_3 = -1$

初始化权重: $\vec{w}^{(0)} = (0,0,0)^T$

$$\text{sign}(\vec{w}^{(0)T} \vec{x}_1) = 0 \neq y_1, \therefore \vec{w}^{(1)} = \vec{w}^{(0)} + y_1 \vec{x}_1 = (1,3,3)^T,$$

$$\text{sign}(\vec{w}^{(1)T} \vec{x}_2) = 1 = y_2, \therefore \vec{w}^{(2)} = \vec{w}^{(1)} = (1,3,3)^T$$

$$\text{sign}(\vec{w}^{(2)T} \vec{x}_3) = 1 \neq y_3, \therefore \vec{w}^{(3)} = \vec{w}^{(2)} + y_3 \vec{x}_3 = (0,2,2)^T$$

$$\text{sign}(\vec{w}^{(3)T} \vec{x}_1) = 1 = y_1, \therefore \vec{w}^{(4)} = \vec{w}^{(3)} = (0,2,2)^T$$

$$\text{sign}(\vec{w}^{(4)T} \vec{x}_2) = 1 = y_2, \therefore \vec{w}^{(5)} = \vec{w}^{(4)} = (0,2,2)^T$$

$$\text{sign}(\vec{w}^{(5)T} \vec{x}_3) = 1 \neq y_3, \therefore \vec{w}^{(6)} = \vec{w}^{(5)} + y_3 \vec{x}_3 = (-1,1,1)^T$$

$$\text{sign}(\vec{w}^{(6)T} \vec{x}_1) = 1 = y_1, \therefore \vec{w}^{(7)} = \vec{w}^{(6)} = (-1,1,1)^T$$

$$\text{sign}(\vec{w}^{(7)T} \vec{x}_2) = 1 = y_2, \therefore \vec{w}^{(8)} = \vec{w}^{(7)} = (-1,1,1)^T$$

$$\text{sign}(\vec{w}^{(8)T} \vec{x}_3) = 1 \neq y_3, \therefore \vec{w}^{(9)} = \vec{w}^{(8)} + y_3 \vec{x}_3 = (-2,0,0)^T$$

$$\text{sign}(\vec{w}^{(9)T} \vec{x}_1) = -1 \neq y_1, \therefore \vec{w}^{(10)} = \vec{w}^{(9)} + y_1 \vec{x}_1 = (-1,3,3)^T$$

$$\text{sign}(\vec{w}^{(10)T} \vec{x}_2) = 1 = y_2, \therefore \vec{w}^{(11)} = \vec{w}^{(10)} = (-1,3,3)^T$$

$$\text{sign}(\vec{w}^{(11)T} \vec{x}_3) = 1 \neq y_3, \therefore \vec{w}^{(12)} = \vec{w}^{(11)} + y_3 \vec{x}_3 = (-2,2,2)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(12)T} \vec{x}_1) = 1 = y_1, \quad \therefore \bar{\mathbf{w}}^{(13)} = \bar{\mathbf{w}}^{(12)} = (-2, 2, 2)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(13)T} \vec{x}_2) = 1 = y_2, \quad \therefore \bar{\mathbf{w}}^{(14)} = \bar{\mathbf{w}}^{(13)} = (-2, 2, 2)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(14)T} \vec{x}_3) = 1 \neq y_3, \quad \therefore \bar{\mathbf{w}}^{(15)} = \bar{\mathbf{w}}^{(14)} + y_3 \vec{x}_3 = (-3, 1, 1)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(15)T} \vec{x}_1) = 1 = y_1, \quad \therefore \bar{\mathbf{w}}^{(16)} = \bar{\mathbf{w}}^{(15)} = (-3, 1, 1)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(16)T} \vec{x}_2) = 1 = y_2, \quad \therefore \bar{\mathbf{w}}^{(17)} = \bar{\mathbf{w}}^{(16)} = (-3, 1, 1)^T$$

$$\text{sign}(\bar{\mathbf{w}}^{(17)T} \vec{x}_3) = -1 = y_3, \quad \therefore \bar{\mathbf{w}}^{(18)} = \bar{\mathbf{w}}^{(17)} = (-3, 1, 1)^T$$

$$\therefore \bar{\mathbf{w}} = (-3, 1, 1)^T, \text{ 分类面为: } x_1 + x_2 - 3 = 0$$

对测试样本进行增广, $\vec{x} = (1, 0, 1)^T$,

$$\text{sign}(\bar{\mathbf{w}}^T \vec{x}) = \text{sign}((-3, 1, 1)(1, 0, 1)^T) = -1, \quad \therefore \vec{x} \in -1 \text{ 类}$$

2, 对于感知器算法 (PLA), 假设第 t 次迭代时, 选择的是第 n 个样

本: $\text{sign}(\mathbf{w}_t^T \mathbf{x}_n) \neq y_n$, $\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + y_n \mathbf{x}_n$, 下述那个式子正确?

(a) $\mathbf{w}_{t+1}^T \mathbf{x}_n = y_n$

(b) $\text{sign}(\mathbf{w}_{t+1}^T \mathbf{x}_n) = y_n$

(c) $y_n \mathbf{w}_{t+1}^T \mathbf{x}_n \geq y_n \mathbf{w}_t^T \mathbf{x}_n$

(d) $y_n \mathbf{w}_{t+1}^T \mathbf{x}_n < y_n \mathbf{w}_t^T \mathbf{x}_n$

3, 证明: 针对线性可分训练样本集, PLA 算法中, 当 $\mathbf{w}_0 = \mathbf{0}$, 在对分

错样本进行了 T 次纠正后, 下式成立: $\frac{\mathbf{w}_f^T}{\|\mathbf{w}_f\|} \frac{\mathbf{w}_T}{\|\mathbf{w}_T\|} \geq \sqrt{T} \cdot \text{constant}$

证明: 由于

$$\begin{aligned}\mathbf{W}_f^T \mathbf{W}_{t+1} &= \mathbf{W}_f^T (\mathbf{W}_t + y_n(t) \mathbf{X}_n(t)) \\ &\geq \mathbf{W}_f^T \mathbf{W}_t + \min_n y_n(t) \mathbf{W}_f^T \mathbf{X}_n(t)\end{aligned}$$

且有 $W_0 = 0$ ，故有 $\mathbf{W}_f^T \mathbf{W}_T \geq T \cdot \min_n y_n \mathbf{W}_f^T \mathbf{X}_n$ ；

又由于

$$\begin{aligned}\|\mathbf{W}_{t+1}\|^2 &= \|\mathbf{W}_t + y_n(t) \mathbf{X}_n(t)\|^2 \\ &= \|\mathbf{W}_t\|^2 + 2y_n(t) \mathbf{W}_t^T \mathbf{X}_n(t) + \|y_n(t) \mathbf{X}_n(t)\|^2 \\ &\leq \|\mathbf{W}_t\|^2 + 0 + \|y_n(t) \mathbf{X}_n(t)\|^2 \\ &\leq \|\mathbf{W}_t\|^2 + \max_n \|\mathbf{X}_n(t)\|^2\end{aligned}$$

故有 $\|\mathbf{W}_T\| \leq \sqrt{T \cdot \max_n \|\mathbf{X}_n\|^2}$ ；

综上所述，有

$$\begin{aligned}\frac{\mathbf{W}_f^T \mathbf{W}_T}{\|\mathbf{W}_f\| \|\mathbf{W}_T\|} &\geq \frac{T \cdot \min_n y_n \mathbf{W}_f^T \mathbf{X}_n}{\|\mathbf{W}_f\| \cdot \sqrt{T \cdot \max_n \|\mathbf{X}_n\|^2}} \\ &= \sqrt{T} \cdot \text{constant}\end{aligned}$$

4，针对线性可分训练样本集，PLA 算法中，假设对分错样本进行了 T 次纠正后得到的分类面不再出现错分状况，定义： $R^2 = \max_n \|\mathbf{x}_n\|^2$ ，

$\rho = \min_n y_n \frac{\mathbf{W}_f^T}{\|\mathbf{W}_f\|} \mathbf{x}_n$ ，试证明： $T \leq \frac{R^2}{\rho^2}$

证明：

$$\begin{aligned}\frac{\mathbf{W}_f^T \mathbf{W}_T}{\|\mathbf{W}_f\| \|\mathbf{W}_T\|} &\geq \frac{T \cdot \min_n y_n \mathbf{W}_f^T \mathbf{X}_n}{\|\mathbf{W}_f\| \cdot \sqrt{T \cdot \max_n \|\mathbf{X}_n\|^2}} \\ &= \sqrt{T} \cdot \frac{\rho}{R}\end{aligned}$$

$$\begin{aligned}
\sqrt{T} &\leq \frac{R}{\rho} \cdot \frac{\mathbf{W}_f^T \mathbf{W}_T}{\|\mathbf{W}_f\| \|\mathbf{W}_T\|} \\
&= \frac{R}{\rho} \cdot \cos \langle \mathbf{W}_f, \mathbf{W}_T \rangle \\
&\leq \frac{R}{\rho}
\end{aligned}$$

因此有

$$T \leq \frac{R^2}{\rho^2}$$

5, 假设训练样本集为 $D = \{(\vec{x}_1, y_1) = ((0.2, 0.7)^T, 1), (\vec{x}_2, y_2) = ((0.3, 0.3)^T, 1), (\vec{x}_3, y_3) = ((0.4, 0.5)^T, 1), (\vec{x}_4, y_4) = ((0.6, 0.5)^T, 1), (\vec{x}_5, y_5) = ((0.1, 0.4)^T, 1), (\vec{x}_6, y_6) = ((0.4, 0.6)^T, -1), (\vec{x}_7, y_7) = ((0.6, 0.2)^T, -1), (\vec{x}_8, y_8) = ((0.7, 0.4)^T, -1), (\vec{x}_9, y_9) = ((0.8, 0.6)^T, -1), (\vec{x}_{10}, y_{10}) = ((0.7, 0.5)^T, -1)\}$, 用 Pocket 算法设计分类面。(可借助编程实现, 迭代次数最多 10 次, 需提交每次迭代的结果)

解: 略

Lecture3 习题作业

1, 假设训练样本集为 $D = \{(\vec{x}_1, y_1) = ((0.2, 0.7)^T, 1), (\vec{x}_2, y_2) = ((0.3, 0.3)^T, 1), (\vec{x}_3, y_3) = ((0.4, 0.5)^T, 1), (\vec{x}_4, y_4) = ((0.6, 0.5)^T, 1), (\vec{x}_5, y_5) = ((0.1, 0.4)^T, 1), (\vec{x}_6, y_6) = ((0.4, 0.6)^T, -1), (\vec{x}_7, y_7) = ((0.6, 0.2)^T, -1), (\vec{x}_8, y_8) = ((0.7, 0.4)^T, -1), (\vec{x}_9, y_9) = ((0.8, 0.6)^T, -1), (\vec{x}_{10}, y_{10}) = ((0.7, 0.5)^T, -1)\}$, 使用线性回归算法 (Linear Regression Algorithm), 通过广义逆来求解, 并设计这两类的分类函数, 讨论结果。

解: 令 $D = \{(\vec{x}_i, y_i) = ((1, x_i^1, x_i^2), y_i)\}, i = 1 \sim 10$, 故可写出

$$\mathbf{X}^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 0.2 & 0.3 & 0.4 & 0.6 & 0.1 & 0.4 & 0.6 & 0.7 & 0.8 & 0.7 \\ 0.7 & 0.3 & 0.5 & 0.5 & 0.4 & 0.6 & 0.2 & 0.4 & 0.6 & 0.5 \end{bmatrix}$$
$$\mathbf{y} = (1, 1, 1, 1, 1, -1, -1, -1, -1, -1)$$

进而计算可得

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$
$$= \begin{bmatrix} -0.16 & 0.7 & 0.11 & -0.1 & 0.67 & -0.13 & 0.63 & 0.04 & -0.55 & -0.20 \\ -0.53 & -0.39 & -0.16 & 0.25 & -0.78 & -0.14 & 0.20 & 0.43 & 0.67 & 0.45 \\ 1.1 & -0.88 & 0.14 & 0.17 & -0.41 & 0.64 & -1.33 & -0.31 & 0.7 & 0.19 \end{bmatrix}$$

于是有


$$\mathbf{W} = \mathbf{X}^\dagger \mathbf{y}$$
$$= (1.43, -3.22, 0.24)^T$$

因此这两类的分类函数为

$$h(\mathbf{x}) = \text{sign}(\mathbf{W}^T \mathbf{x})$$

其中 $\mathbf{W} = (1.43, -3.22, 0.24)^T$

并且将训练样本集 $D = \{(\vec{x}_i, y_i) = ((1, x_i^1, x_i^2), y_i)\}, i = 1 \sim 10$ 代入所得的分类函数 $h(\mathbf{x}) = \text{sign}(\mathbf{W}^T \mathbf{x})$ 可得该分类函数可大致正确分类训练样本。



2，根据向量或矩阵的计算性质，证明：

$$\|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 = \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y}$$

解：

$$\begin{aligned} \|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 &= (\mathbf{X}\mathbf{w} - \mathbf{Y})^T (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= ((\mathbf{X}\mathbf{w})^T - \mathbf{Y}^T) (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= (\mathbf{w}^T \mathbf{X}^T - \mathbf{Y}^T) (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - \mathbf{Y}^T \mathbf{X} \mathbf{w} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - (\mathbf{X}\mathbf{w})^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \end{aligned}$$

3, 总结梯度下降法、随机梯度下降法、Adagrad、RMSProp、动量法 (Momentum) 和 Adam 等方法权系数更新表达式。

解: 对于任意的损失函数 L , 假设任一单个样本 n 的梯度 $\nabla L_n(\mathbf{w})$, t 代表迭代次数

(1) 梯度下降法:

$$\nabla L_{in}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \nabla L_n(\mathbf{w})$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \nabla L_{in}(\mathbf{w}_t)$$

(2) 随机梯度下降法:

$$\nabla L_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla L_n(\mathbf{w}), B \text{ 代表批量大小, 最小可以为 } 1$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \nabla L_{in}(\mathbf{w}_t)$$

(3) Adagrad:

$$\nabla L_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla L_n(\mathbf{w})$$

$$\sigma_t = \sqrt{\frac{1}{t+1} \sum_{t=0}^t (\nabla L_{in}(\mathbf{w}))^2 + \varepsilon}, \varepsilon \text{ 代表极小量, 防止 } \sigma_t \text{ 为 } 0$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \frac{\eta}{\sigma_t} \nabla L_{in}(\mathbf{w}_t)$$

(4) RMSProp:

$$\nabla L_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla L_n(\mathbf{w})$$

$$\sigma_{t-1} = \sqrt{\frac{1}{t} \sum_{t=0}^{t-1} (\nabla L_{in}(\mathbf{w}))^2}$$

$$\sigma_t = \sqrt{\alpha (\sigma_{t-1})^2 + (1 - \alpha) (\nabla L_{in}(\mathbf{w}))^2 + \varepsilon}$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \frac{\eta}{\sigma_t} \nabla L_{in}(\mathbf{w}_t)$$

(5) 动量法 (Momentum):

$$\nabla L_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla L_n(\mathbf{w})$$

$$\mathbf{m}_{t+1} = \lambda \mathbf{m}_t - \eta \nabla L_{in}(\mathbf{w}_t), \quad (\mathbf{m}_0 = \mathbf{0})$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \mathbf{m}_{t+1}$$

(6) Adam

$$\mathbf{m}_{t+1} = \beta_1 \mathbf{m}_t - (1 - \beta_1) \nabla L_{in}(\mathbf{w}_t), \quad (\mathbf{m}_0 = \mathbf{0})$$

$$\mathbf{v}_{t+1} = \beta_2 \mathbf{v}_t - (1 - \beta_2) (\nabla L_{in}(\mathbf{w}))^2, \quad (\mathbf{v}_0 = \mathbf{0})$$

$$\hat{\mathbf{m}}_{t+1} = \mathbf{m}_{t+1} / (1 - \beta_1^{t+1})$$

$$\hat{\mathbf{v}}_{t+1} = \mathbf{v}_{t+1} / (1 - \beta_2^{t+1})$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \hat{\mathbf{m}}_{t+1} / (\sqrt{\hat{\mathbf{v}}_{t+1}} + \varepsilon)$$

版权归SMART-AIA-HUST所有，严禁复制

Lecture4 习题作业

1, 已知两类样本的数据如下:

$$\omega_1: \{(5,37), (7,30), (10,35), (11.5,40), (14,38), (12,31)\}$$

$$\omega_2: \{(35,21.5), (39,21.7), (34,16), (37,17)\}$$

试用 Fisher 判别函数法, 求出最佳投影方向 W , 及分类阈值 y_0

解: 由题意知:

$$\mu_1 = \frac{1}{6} \sum_{n=1}^6 X_n^{(1)} = (9.92 \ 35.17)^T$$

$$\mu_0 = \frac{1}{4} \sum_{n=1}^4 X_n^{(0)} = (36.25 \ 19.05)^T$$

则可计算出类内离差阵:

$$\Sigma_1 = \sum_{n=1}^6 (X_n^{(1)} - \mu_1) \cdot (X_n^{(1)} - \mu_1)^T = \begin{pmatrix} 56.21 & 16.58 \\ 16.58 & 78.83 \end{pmatrix}$$

$$\Sigma_0 = \sum_{n=1}^4 (X_n^{(0)} - \mu_0) \cdot (X_n^{(0)} - \mu_0)^T = \begin{pmatrix} 14.75 & 9.55 \\ 9.55 & 26.53 \end{pmatrix}$$

$$S_w = \Sigma_1 + \Sigma_0 = \begin{pmatrix} 70.96 & 26.13 \\ 26.13 & 105.36 \end{pmatrix}$$

$$S_w^{-1} = \begin{pmatrix} 0.0155 & -0.0038 \\ -0.0038 & 0.0104 \end{pmatrix}$$

从而可计算出最佳投影方向:

$$W^* = S_w^{-1}(\mu_1 - \mu_0) = (-0.4704, 0.2696)^T$$

$$y_0 = W^{*T} \frac{(\mu_1 + \mu_0)}{2} = -3.55$$

2, 在 Fisher 判别中, 用向量梯度的计算法则证明: $\mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$

证明: $L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_B \mathbf{w} + \lambda(K - \mathbf{w}^T \mathbf{S}_w \mathbf{w}) = \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w} + \lambda K$

$$\nabla L_w(\mathbf{w}, \lambda) = \frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \mathbf{0}^T$$

$$\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \frac{\partial (\mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w})}{\partial \mathbf{w}} + 0$$

根据 $\frac{\partial \mathbf{u}^T \mathbf{v}}{\partial \mathbf{x}} = \mathbf{u}^T \frac{\partial \mathbf{v}}{\partial \mathbf{x}} + \mathbf{v}^T \frac{\partial \mathbf{u}}{\partial \mathbf{x}}$, $\frac{\partial A \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}$, 以及 $\frac{\partial \mathbf{x}}{\partial \mathbf{x}} = \mathbf{I}$, 上式:

$$\begin{aligned} \frac{\partial (\mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w})}{\partial \mathbf{w}} &= \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{I} + ((\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w})^T \mathbf{I} \\ &= \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{I} + \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w)^T \mathbf{I} \end{aligned}$$

因为: $\mathbf{S}_B$ 和 $\mathbf{S}_w$ 均为对称矩阵,

所以: $(\mathbf{S}_B - \lambda \mathbf{S}_w)^T = (\mathbf{S}_B - \lambda \mathbf{S}_w)$,

又: $(\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{I} = (\mathbf{S}_B - \lambda \mathbf{S}_w)$

所以: $\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = 2 \mathbf{w}^T (\mathbf{S}_B - \lambda \mathbf{S}_w) = \mathbf{0}^T$

$$2(\mathbf{S}_B - \lambda \mathbf{S}_w) \mathbf{w} = \mathbf{0}$$

$$\mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

Lecture5 习题作业

1, 有人说当批量大小为 1 时基于随机梯度下降法 (Stochastic Gradient Descent, SGD) 的逻辑斯蒂回归 (Logistic Regression) 算法可以被看作“软性”的感知器算法 (PLA), 你认同这个说法吗? 请给出你的理由。

解: 进行二分类, 标签为+1 和-1 时, 上述说法正确。

Logistic Regression 算法在利用随机梯度下降法的权向量更新表达式为: $\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \theta(-y_n \mathbf{w}_t^T \mathbf{x}_n)(-y_n \mathbf{x}_n)$

感知器算法 (PLA) 的权向量更新表达式为:

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \llbracket \text{sign}(\mathbf{w}_t^T \mathbf{x}_{n(t)}) \neq y_n \rrbracket \mathbf{x}_{n(t)}$$

当 $\eta = 1$ 时, 逻辑斯蒂回归中的 Sigmoid 函数取值在 0 和 1 之间, 而 PLA 的 BOOL 表达式取值不是 0 就是 1, 所以, 可以认为前者是“软性”的 PLA。

2, 在 Logistic regression 中当标签 $y=\{+1,-1\}$ 时常用交叉熵作为损失函数: $L_{in}(\mathbf{w}) = \frac{1}{N} \sum_1^N \ln(1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n))$, 请推导出该函数的梯度表达式。

解: $L_{in} = \ln(1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n))$,

$$\begin{aligned} \frac{\partial L_{in}(\mathbf{w}, \mathbf{x}, y)}{\partial w_i} &= \frac{\partial \ln(1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n))}{\partial (1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n))} \frac{\partial (1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n))}{\partial (-y_n \mathbf{w}^T \mathbf{x}_n)} \frac{\partial (-y_n \mathbf{w}^T \mathbf{x}_n)}{\partial w_i} \\ &= \frac{1}{1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n)} \exp(-y_n \mathbf{w}^T \mathbf{x}_n) (-y x_i) \\ &= \frac{\exp(-y_n \mathbf{w}^T \mathbf{x}_n)}{1 + \exp(-y_n \mathbf{w}^T \mathbf{x}_n)} (-y x_i) \end{aligned}$$

$$\nabla L_{in}(\mathbf{w}, \mathbf{x}, y) = \theta(-y \mathbf{w}^T \mathbf{x})(-y \mathbf{x})$$

3, 为什么在 Logistic Regression 中不用 $L_{in}(\mathbf{w}) = (\theta(y\mathbf{w}^T \mathbf{x}) - 1)^2$ 作为损失函数, 这里假设 $\theta(\cdot)$ 是 *Sigmoid* 函数, 标签 $y = \{+1, -1\}$ 。

解: $L_{in}(\mathbf{w}) = (\theta(y\mathbf{w}^T \mathbf{x}) - 1)^2$

$$\frac{\partial L_{in}(\mathbf{w}, \mathbf{x}, y)}{\partial w_i} = 2(\theta(y\mathbf{w}^T \mathbf{x}) - 1)\theta(y\mathbf{w}^T \mathbf{x})(1 - \theta(y\mathbf{w}^T \mathbf{x}))yx_i$$

$$\text{if } (y\mathbf{w}^T \mathbf{x}) > 0 \quad \nabla L_{in}(\mathbf{w}, \mathbf{x}, y) = 0$$

$$\text{if } (y\mathbf{w}^T \mathbf{x}) < 0 \quad \nabla L_{in}(\mathbf{w}, \mathbf{x}, y) = 0$$

无论分类正确与否, 梯度都为 0, 影响学习性能。

Lecture7-8 作业

1 , 假设两个样本 $\{(\mathbf{v}_1, y_1) = ((v_1, v_2)^T, 1), (\mathbf{v}_2, y_2) = ((-v_1, -v_2)^T, -1)\}$, 假设 H 是这两个样本的最大间隔分类面, 写出其表达式。

解: 两个样本关于原点对称, 最大间隔分类面会垂直于两个样本的连线, 且穿过原点, 即样本连线的斜率与分类面(分类线)斜率的乘积为-1, 而样本连线的斜率为 $\frac{v_2}{v_1}$, 所以, 分类面(线)的斜率为: $-\frac{v_1}{v_2}$, 且 $b=0$ 。

所以, 最大间隔分类面为:

$$x_2 = -\frac{v_1}{v_2} x_1$$

$$\text{即: } v_1 x_1 + v_2 x_2 = 0$$

2 , 假设三个样本为 $D = \{(\mathbf{x}_1, y_1) = ((3, 0)^T, 1), (\mathbf{x}_2, y_2) = ((0, 4)^T, 1), (\mathbf{x}_3, y_3) = ((0, 0)^T, -1)\}$, 计算这三个样本到平面: $x_1 + x_2 = 1$ 的距离。

解: $d = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$

$$x_1 + x_2 = 1 \rightarrow x_1 + x_2 - 1 = 0$$

$$d_1 = \frac{|\mathbf{w}^T \mathbf{x}_1 + b|}{\|\mathbf{w}\|} = \frac{|(1, 1) \begin{pmatrix} 3 \\ 0 \end{pmatrix} - 1|}{\sqrt{(1^2 + 1^2)}} = \sqrt{2}$$

$$d_2 = \frac{|\mathbf{w}^T \mathbf{x}_2 + b|}{\|\mathbf{w}\|} = \frac{|(1, 1) \begin{pmatrix} 0 \\ 4 \end{pmatrix} - 1|}{\sqrt{(1^2 + 1^2)}} = \frac{3}{2} \sqrt{2}$$

$$d_3 = \frac{|\mathbf{w}^T \mathbf{x}_3 + b|}{\|\mathbf{w}\|} = \frac{|(1,1) \begin{pmatrix} 0 \\ 0 \end{pmatrix} - 1|}{\sqrt{(1^2 + 1^2)}} = \frac{\sqrt{2}}{2}$$

3，假设训练样本集为 $D = \{(\mathbf{x}_1, y_1) = ((0,0)^T, -1), (\mathbf{x}_2, y_2) = ((2,2)^T, -1), (\mathbf{x}_3, y_3) = ((2,0)^T, 1), (\mathbf{x}_4, y_4) = ((3,0)^T, 1)\}$ ，使用 QP 求解器时， $\mathbf{a}_n^T (n=1,2,3,4)$ 分别为多少？

解： $\mathbf{a}_1^T = (-1, 0, 0)$ ， $\mathbf{a}_2^T = (-1, -2, -2)$ ， $\mathbf{a}_3^T = (1, 2, 0)$ ， $\mathbf{a}_4^T = (1, 3, 0)$

4，假设训练样本集为： $D = \{(\mathbf{x}_1, y_1) = ((1,1)^T, 1), (\mathbf{x}_2, y_2) = ((2,2)^T, 1), (\mathbf{x}_3, y_3) = ((2,0)^T, 1), (\mathbf{x}_4, y_4) = ((0,0)^T, -1), (\mathbf{x}_5, y_5) = ((1,0)^T, -1), (\mathbf{x}_6, y_6) = ((0,1)^T, -1)\}$ ，请分别在 $y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1$ 和 $y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 5$ 的条件下用 Primal SVM 方法来设计最优分类面 $g(\mathbf{x})$ ，判断两种情况下的分类面是否一致，指出哪些是候选的支撑向量，并回答如何确认哪些是支撑向量。

解：（1）对于条件 $y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1$ ，可列出如下的式子

$$\begin{aligned} \min_{b, \mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & \begin{cases} w_1 + w_2 + b \geq 1 \\ 2w_1 + 2w_2 + b \geq 1 \\ 2w_1 + b \geq 1 \\ -b \geq 1 \\ -w_1 - b \geq 1 \\ -w_2 - b \geq 1 \end{cases} \implies \begin{cases} w_1 \geq 2 \\ w_2 \geq 2 \\ b \leq -3 \end{cases} \end{aligned}$$

当且仅当 $w_1 = 2, w_2 = 2, b = -3$ ，

$$\frac{1}{2} \mathbf{w}^T \mathbf{w} = \frac{1}{2} (w_1^2 + w_2^2) \geq \frac{1}{2} (2^2 + 2^2) = 4 \text{ 取得最小值。}$$

可以验证 constraints 均满足。

故此时的最优分类面为

$$\mathbf{w}_1^T \mathbf{x} + b_1 = 0$$

其中 $\mathbf{w}_1 = [2 \ 2]^T, b_1 = -3$ 。

可以验证，将 $\mathbf{w}_1 = [2 \ 2]^T, b_1 = -3$ 代入上述 constraints 中有第 1、

3、5、6 是严格等式，故候选支撑向量为 $\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 。

由 Dual SVM 知识可知，当求解 Dual SVM 问题时，在如下式子中

$$\alpha_n (1 - y_n (\mathbf{w}^T \mathbf{x}_n + b)) = 0$$

$\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 满足 $\alpha_n > 0, y_n (\mathbf{w}^T \mathbf{x}_n + b) = 1$ 所对应的样本即为支撑向量。

(2) 对于条件 $y_n (\vec{w}^T \vec{x}_n + b) \geq 5$ ，可列出如下的式子

$$\begin{aligned} \min_{b, \mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & \begin{cases} w_1 + w_2 + b \geq 5 \\ 2w_1 + 2w_2 + b \geq 5 \\ 2w_1 + b \geq 5 \\ -b \geq 5 \\ -w_1 - b \geq 5 \\ -w_2 - b \geq 5 \end{cases} \implies \begin{cases} w_1 \geq 10 \\ w_2 \geq 10 \\ b \leq -15 \end{cases} \end{aligned}$$

当且仅当 $w_1 = 10, w_2 = 10, b = -15$ 时有

$$\frac{1}{2} \mathbf{w}^T \mathbf{w} = \frac{1}{2} (w_1^2 + w_2^2) \geq \frac{1}{2} (10^2 + 10^2) = 100 \text{ 取得最小值,}$$

可以验证 constraints 均满足。

故此时的最优分类面为

$$\mathbf{w}_2^T \mathbf{x} + b_2 = 0, \text{ which is exactly equivalent to } \mathbf{w}_1^T \mathbf{x} + b_1 = 0$$

其中 $\mathbf{w}_2 = [10 \ 10]^T, b_2 = -15$ 。

可以验证，将 $\mathbf{w}_2 = [10 \ 10]^T, b_2 = -15$ 代入上述 constraints 中有第 1、3、5、6 是严格等式，故候选支撑向量为 $\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 。

由 Dual SVM 知识可知，当求解 Dual SVM 问题时，在如下式子中

$$\alpha_n (1 - y_n (\mathbf{w}^T \mathbf{x}_n + b)) = 0$$

$\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 满足 $\alpha_n > 0, y_n (\mathbf{w}^T \mathbf{x}_n + b) = 5$ 所对应的样本即为支撑向量。

5, Hinge Loss 是支撑向量机的误差函数，因此，除了用二次规划求解最佳分类面外，也能用梯度下降法求解，（1）请推导梯度并写出算法流程；（2）假设初始增广权向量 $\vec{w} = (0,0,0)^T$ ，用第 4 题训练样本集去设计分类面，指出哪些向量在边界上？假设它们都是支撑向量的话，请问最佳权系数向量是否是这些支撑向量的线性组合？

解：（1）已知样本集合 $\{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_N, y_N)\}$
 $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ ，每个样本的标签为 $y_n \in \{+1, -1\}$ ，
我们基于 Hinge Loss，对于每个样本定义其误差函数为：

$$err_{SVM} = \max(0, 1 - y_n (\mathbf{w}^T \mathbf{x}_n + b))$$

对其求梯度，得到：

$$\text{当 } 1 - y_n (\mathbf{w}^T \mathbf{x}_n + b) \geq 0, \quad \frac{\partial L_{in}(\mathbf{w})}{\partial \mathbf{w}} = -y_n \mathbf{x}_n$$

$$\text{当 } 1 - y_n (\mathbf{w}^T \mathbf{x}_n + b) < 0, \quad \frac{\partial L_{in}(\mathbf{w})}{\partial \mathbf{w}} = 0$$

利用随机梯度下降法得到新的 $\mathbf{w}$

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \frac{\partial L_{in}(\mathbf{w}^{(t)})}{\partial \mathbf{w}^{(t)}} = \mathbf{w}^{(t)} + \eta \mathbb{I}[1 - y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 0] y_n \mathbf{x}_n$$

$$\text{其中, } \mathbb{I}[\cdot] = \begin{cases} 1, & \text{if condition is satisfied} \\ 0, & \text{otherwise} \end{cases}$$

(2) 初始增广权向量 $\mathbf{w}^{(0)} = (0,0,0)^T$

$$\mathbf{x}_1 = (1,1,1)^T, \mathbf{x}_2 = (1,2,2)^T, \mathbf{x}_3 = (1,2,0)^T,$$

$$\mathbf{x}_4 = (1,0,0)^T, \mathbf{x}_5 = (1,1,0)^T, \mathbf{x}_6 = (1,0,1)^T$$

$$y_1 = 1, y_2 = 1, y_3 = 1, y_4 = -1, y_5 = -1, y_6 = -1$$

取学习率 $\eta = 1$

第一轮迭代

$$\max(0, 1 - y_1 (\mathbf{w}^{(0)T} \mathbf{x}_1)) = \max(0, 1) = 1$$

$$\frac{\partial L_{in}(\mathbf{w}^{(0)})}{\partial \mathbf{w}^{(0)}} = -y_1 \mathbf{x}_1 = (-1, -1, -1)^T$$

$$\mathbf{w}^{(1)} = \mathbf{w}^{(0)} - \eta \frac{\partial L_{in}(\mathbf{w}^{(0)})}{\partial \mathbf{w}^{(0)}} = \mathbf{w}^{(0)} + y_1 \mathbf{x}_1 = (1, 1, 1)^T$$

第二轮迭代

$$\max(0, 1 - y_2 (\mathbf{w}^{(1)T} \mathbf{x}_2)) = \max(0, -4) = 0$$

$$\mathbf{w}^{(2)} = \mathbf{w}^{(1)} = (1, 1, 1)^T$$

第三轮迭代

$$\max(0, 1 - y_3 (\mathbf{w}^{(2)T} \mathbf{x}_3)) = \max(0, -2) = 0$$

$$\mathbf{w}^{(3)} = \mathbf{w}^{(2)} = (1, 1, 1)^T$$

第四轮迭代

$$\max\left(0, 1 - y_4 \left(\mathbf{w}^{(3)T} \mathbf{x}_4\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial L_{in}(\mathbf{w}^{(3)})}{\partial \mathbf{w}^{(3)}} = -y_4 \mathbf{x}_4 = (1, 0, 0)^T$$

$$\mathbf{w}^{(4)} = \mathbf{w}^{(3)} + y_4 \mathbf{x}_4 = (0, 1, 1)^T$$

第五轮迭代

$$\max\left(0, 1 - y_5 \left(\mathbf{w}^{(4)T} \mathbf{x}_5\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial L_{in}(\mathbf{w}^{(4)})}{\partial \mathbf{w}^{(4)}} = -y_5 \mathbf{x}_5 = (1, 1, 0)^T$$

$$\mathbf{w}^{(5)} = \mathbf{w}^{(4)} + y_5 \mathbf{x}_5 = (-1, 0, 1)^T$$

第六轮迭代

$$\max\left(0, 1 - y_6 \left(\mathbf{w}^{(5)T} \mathbf{x}_6\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial L_{in}(\mathbf{w}^{(5)})}{\partial \mathbf{w}^{(5)}} = -y_6 \mathbf{x}_6 = (1, 0, 1)^T$$

$$\mathbf{w}^{(6)} = \mathbf{w}^{(5)} + y_6 \mathbf{x}_6 = (-2, 0, 0)^T$$

第七轮迭代

$$\max\left(0, 1 - y_1 \left(\mathbf{w}^{(6)T} \mathbf{x}_1\right)\right) = \max(0, 3) = 3$$

$$\frac{\partial L_{in}(\mathbf{w}^{(7)})}{\partial \mathbf{w}^{(7)}} = -y_1 \mathbf{x}_1 = (-1, -1, -1)^T$$

$$\mathbf{w}^{(7)} = \mathbf{w}^{(6)} + y_1 \mathbf{x}_1 = (-1, 1, 1)^T$$

第八轮迭代

$$\max\left(0, 1 - y_2 \left(\mathbf{w}^{(7)T} \mathbf{x}_2\right)\right) = \max(0, -2) = 0$$

$$\mathbf{w}^{(8)} = \mathbf{w}^{(7)} = (-1, 1, 1)^T$$

第九轮迭代

$$\max\left(0, 1 - y_3 \left(\mathbf{w}^{(8)T} \mathbf{x}_3\right)\right) = \max(0, 0) = 0$$

$$\frac{\partial L_{in}(\mathbf{w}\mathbf{w}^{(8)})}{\partial \mathbf{w}^{(8)}} = -y_3 \mathbf{x}_3 = (-1, -2, 0)^T$$

$$\mathbf{w}^{(9)} = \mathbf{w}\mathbf{w}^{(8)} + y_3 \mathbf{x}_3 = (0, 3, 1)^T$$

第十轮迭代

$$\max\left(0, 1 - y_4 \left(\mathbf{w}^{(9)^T} \mathbf{x}_4\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial L_{in}(\mathbf{w}\mathbf{w}^{(9)})}{\partial \mathbf{w}^{(9)}} = -y_4 \mathbf{x}_4 = (1, 0, 0)^T$$

$$\mathbf{w}^{(10)} = \mathbf{w}^{(9)} + y_4 \mathbf{x}_4 = (-1, 3, 1)^T$$

第十一轮迭代

$$\max\left(0, 1 - y_5 \left(\mathbf{w}^{(10)^T} \mathbf{x}_5\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial L_{in}(\mathbf{w}^{(4)})}{\partial \mathbf{w}^{(4)}} = -y_5 \mathbf{x}_5 = (1, 1, 0)^T$$

$$\mathbf{w}^{(11)} = \mathbf{w}^{(10)} + y_5 \mathbf{x}_5 = (-2, 2, 1)^T$$

第十二轮迭代

$$\max\left(0, 1 - y_6 \left(\mathbf{w}^{(11)^T} \mathbf{x}_6\right)\right) = \max(0, 0) = 0$$

$$\frac{\partial L_{in}(\mathbf{w}^{(11)})}{\partial \mathbf{w}^{(11)}} = -y_6 \mathbf{x}_6 = (1, 0, 1)^T$$

$$\mathbf{w}^{(12)} = \mathbf{w}^{(11)} + y_6 \mathbf{x}_6 = (-3, 2, 0)^T$$

第十三轮迭代

$$\max\left(0, 1 - y_1 \left(\mathbf{w}^{(12)^T} \mathbf{x}_1\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial L_{in}(\mathbf{w}^{(12)})}{\partial \mathbf{w}^{(12)}} = -y_1 \mathbf{x}_1 = (-1, -1, -1)^T$$

$$\mathbf{w}^{(7)} = \mathbf{w}^{(6)} + y_1 \mathbf{x}_1 = (-2, 3, 1)^T$$

第十四轮迭代

对于 $\mathbf{x}_2$ 、 $\mathbf{x}_3$ 、 $\mathbf{x}_4$ 满足 $1 - y_n (\mathbf{w}^{(13)^T} \mathbf{x}_n) < 0$

$$\max(0, 1 - y_5 (\mathbf{w}^{(13)^T} \mathbf{x}_5)) = \max(0, 2) = 2$$

$$\mathbf{w}^{(14)} = \mathbf{w}^{(13)} + y_5 \mathbf{x}_5 = (-3, 2, 1)^T$$

第十五轮迭代

对于 $\mathbf{x}_6$ 满足 $1 - y_n (\mathbf{w}^{(13)^T} \mathbf{x}_n) < 0$

$$\max(0, 1 - y_1 (\mathbf{w}^{(14)^T} \mathbf{x}_1)) = \max(0, 1) = 1$$

$$\mathbf{w}^{(15)} = \mathbf{w}^{(14)} + y_1 \mathbf{x}_1 = (-2, 3, 2)^T$$

第十六轮迭代

对于 $\mathbf{x}_2$ 、 $\mathbf{x}_3$ 、 $\mathbf{x}_4$ 满足 $1 - y_n (\mathbf{w}^{(15)^T} \mathbf{x}_n) < 0$

$$\max(0, 1 - y_5 (\mathbf{w}^{(15)^T} \mathbf{x}_5)) = \max(0, 2) = 2$$

$$\mathbf{w}^{(16)} = \mathbf{w}^{(15)} + y_5 \mathbf{x}_5 = (-3, 2, 2)^T$$

检验对任意 $\mathbf{x}_n$ 满足 $1 - y_n (\mathbf{w}^{(15)^T} \mathbf{x}_n) < 0$ ，迭代结束

得到分类面为 $2x_1 + 2x_2 - 3 = 0$

$$\vec{w} = (-3, 2, 2)^T$$

将 $\mathbf{x}_1$ 、 $\mathbf{x}_3$ 、 $\mathbf{x}_5$ 、 $\mathbf{x}_6$ 代入 $1 - y_n(\mathbf{w}^T \mathbf{x}_n + b)$ 均为 0，

说明这四个样本在边界上，均为候选的支撑向量。

为简单起见（不用求解对偶 SVM），按照本题题意候选的支撑向量均

为支撑向量，则： $\mathbf{w} = 7x_1 + 0x_3 - 5x_5 - 5x_6$ ，即最佳权系数向量为

支撑向量的线性组合。

6，假如做了非线性变换后的两个训练样本为： $\{(\mathbf{Z}_1, +1) = (\mathbf{z}, 1), (\mathbf{Z}_2, -1) = (-\mathbf{z}, -1)\}$ ，请写出用于设计硬间隔 SVM 时的拉格朗日函数 $L(\mathbf{w}, b, \alpha)$ 。

解：根据定义：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \alpha_1 (1 - y_1 (\mathbf{w}^T \mathbf{Z}_1 + b)) + \alpha_2 (1 - y_2 (\mathbf{w}^T \mathbf{Z}_2 + b))$$

将两个样本代入，得到：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \alpha_1 (1 - (\mathbf{w}^T \mathbf{z} + b)) + \alpha_2 (1 + (-\mathbf{w}^T \mathbf{z} + b))$$

7，对于一个单变量 w ，假设要在 $w \geq 1$ 和 $w \leq 3$ 这两个线性约束条件下，求 $\frac{1}{2} w^2$ 的最小值，请写出其拉格朗日函数 $L(w, \alpha)$ 以及这个最优问题的 KKT 条件。

解：由于是单变量，根据定义及约束条件：

$$L(w, \alpha) = \frac{1}{2} w^2 + \alpha_1 (1 - w) + \alpha_2 (w - 3)$$

KKT 条件为：

$$\alpha_1 \geq 0, \alpha_2 \geq 0,$$

$$w = \alpha_1 - \alpha_2, \left(\text{通过 } \frac{\partial L(w, \alpha)}{\partial w} = 0 \text{ 得到} \right)$$

$$\alpha_1 (1 - w) = 0, \alpha_2 (w - 3) = 0.$$

8，假如做了非线性变换后的两个训练样本为： $\{(\mathbf{Z}_1, +1) = (\mathbf{z}, 1), (\mathbf{Z}_2, -1) = (-\mathbf{z}, -1)\}$ ，在求解硬间隔 SVM 的对偶问题时，假定得到的最佳 $\alpha_1 > 0$ ，最佳 $\alpha_2 > 0$ ，请问最佳 b 为多少？

解：由于 $\alpha_1 > 0$, $\alpha_2 > 0$, 所以: $\mathbf{z}_1$ 和 $\mathbf{z}_2$ 为支撑向量, 根据定义:

$$b = y_1 - \mathbf{w}^T \mathbf{z}_1 = y_2 - \mathbf{w}^T \mathbf{z}_2 = 1 - \mathbf{w}^T \mathbf{z} = -1 + \mathbf{w}^T \mathbf{z}$$

得到: $\mathbf{w}^T \mathbf{z} = 1$, $b = 0$

9, 假设有 5566 个样本用以训练对偶硬间隔 SVM 时得到 1126 个支撑向量, 请问落在分类面边界上的样本数 (也就是候选的支撑向量) 有可能是: (a) 0; (b) 1024; (c) 1234; (d) 9999。

解: 因为: 支撑向量数 $\leq$ 候选的支撑向量数 $\leq$ 样本总数

所以选择 (c)

10, 如果两个样本 $\mathbf{x}$ 和 $\mathbf{x}'$ 的内积 $\mathbf{x}^T \mathbf{x}' = 10$, 计算其 ϕ_2 核函数 $K_{\phi_2}(\mathbf{x}, \mathbf{x}')$ 等于多少?

解: 因为: $K_{\phi_2}(\mathbf{x}, \mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$

所以: $K_{\phi_2}(\mathbf{x}, \mathbf{x}') = 1 + 10 + 100 = 111$

11, 假设训练样本集为: $D = \{(\mathbf{x}_1, y_1) = ((2, 2)^T, 1), (\mathbf{x}_2, y_2) = ((-2, -2)^T, 1), (\mathbf{x}_3, y_3) = ((2, -2)^T, -1), (\mathbf{x}_4, y_4) = ((-2, 2)^T, -1)\}$,

请用 Dual SVM 来设计最优分类面 $g(\mathbf{x})$, 并指出哪些是支撑向量。

解: 样本为非线性分布, 所以, 需要首先进行非线性变换:

$$\text{令 } \phi_2(\vec{x}) = \{1, x_1, x_2, x_1 x_2, x_1^2, x_2^2\}$$

$$\text{则: } (\mathbf{x}_1, y_1) \rightarrow (\mathbf{z}_1, y_1): \{(2, 2)^T, 1\} \rightarrow \{(1, 2, 2, 4, 4, 4)^T, 1\}$$

$$(\mathbf{x}_2, y_2) \rightarrow (\mathbf{z}_2, y_2): \{(-2, -2)^T, 1\} \rightarrow \{(1, -2, -2, 4, 4, 4)^T, 1\}$$

$$(\mathbf{x}_3, y_3) \rightarrow (\mathbf{z}_3, y_3): \{(-2, 2)^T, -1\} \rightarrow \{(1, -2, 2, -4, 4, 4)^T, -1\}$$

$$(\mathbf{x}_4, y_4) \rightarrow (\mathbf{z}_4, y_4): \{(2, -2)^T, -1\} \rightarrow \{(1, 2, -2, -4, 4, 4)^T, -1\}$$

$$\text{令 } \alpha_1 \geq 0, \alpha_2 \geq 0, \alpha_3 \geq 0, \alpha_4 \geq 0$$

由 SVM 对偶模型得到：

$$\begin{cases} L(\mathbf{w}, b, \alpha) = \frac{1}{2} \sum_{n=1}^4 \sum_{m=1}^4 \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^4 \alpha_n \\ \sum_{n=1}^4 y_n \alpha_n = 0 \end{cases}$$

$$\text{求 } L(\mathbf{w}, b, \alpha) \text{ 对 } \alpha \text{ 的梯度: } \frac{\partial L}{\partial \alpha_n} = \sum_{m=1}^4 \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - 1$$

$$\text{且: } \alpha_1 + \alpha_2 - \alpha_3 - \alpha_4 = 0$$

代入训练样本，

$$\frac{\partial L}{\partial \alpha_1} = 57\alpha_1 + 41\alpha_2 - 17\alpha_3 - 17\alpha_4 - 1 = 0 \rightarrow 40\alpha_1 + 24\alpha_2 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_2} = 57\alpha_2 + 41\alpha_1 - 17\alpha_3 - 17\alpha_4 - 1 = 0 \rightarrow 40\alpha_2 + 24\alpha_1 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_3} = 57\alpha_3 - 17\alpha_1 - 17\alpha_2 + 41\alpha_4 - 1 = 0 \rightarrow 40\alpha_3 + 24\alpha_4 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_4} = 57\alpha_4 - 17\alpha_1 - 17\alpha_2 + 41\alpha_3 - 1 = 0 \rightarrow 40\alpha_4 + 24\alpha_3 - 1 = 0$$

$$\text{求解得到: } \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \frac{1}{64}$$

$$\therefore \mathbf{w} = \sum_{n=1}^4 \alpha_n y_n \mathbf{z}_n = \frac{1}{64} (\mathbf{z}_1 + \mathbf{z}_2 - \mathbf{z}_3 - \mathbf{z}_4) = (0, 0, 0, \frac{1}{4}, 0, 0)^T$$

$$b = y_1 - \mathbf{w}^T \mathbf{z}_1 = 1 - \left(0, 0, 0, \frac{1}{4}, 0, 0\right) (1, 2, 2, 4, 4, 4)^T = 0$$

$$\therefore g_{SVM} = \text{sign}(\mathbf{w}^T \phi_2(\mathbf{x}) + b) = \text{sign}\left(\frac{1}{4} x_1 x_2\right)$$

且四个样本均为支撑向量。

Lecture 9 习题作业

1, 假设有如下训练样本: $\mathbf{x}_1 = (0,0)^T$ 属于第一类, $\mathbf{x}_2 = (1,1)^T$ 属于第二类, $\mathbf{x}_3 = (-1,1)^T$ 属于第三类, 请用多类分类中的 OVO (One-versus-one) 策略, 设计上述三类别的两两分类器, 并分析测试样本 $\mathbf{x} = (1,-2)^T$ 属于哪个类别。

解: 利用 OVO 策略, 对三个类别两两求分类面:

(1) 用感知器算法求第一类和第二类之间的分类面

样本增广后为: $\mathbf{x}_1 = (1,0,0)^T$, $y_1 = 1$, $\mathbf{x}_2 = (1,1,1)^T$, $y_2 = -1$,

初始化权重: $\mathbf{w}_{[1,2]}^{(0)} = (0,0,0)^T$

$$\text{sign}(\mathbf{w}_{[1,2]}^{(0)T} \mathbf{x}_1) = 0 \neq y_1, \therefore \mathbf{w}_{[1,2]}^{(1)} = \mathbf{w}_{[1,2]}^{(0)} + y_1 \mathbf{x}_1 = (1,0,0)^T,$$

$$\text{sign}(\mathbf{w}_{[1,2]}^{(1)T} \mathbf{x}_2) = 1 \neq y_2, \therefore \mathbf{w}_{[1,2]}^{(2)} = \mathbf{w}_{[1,2]}^{(1)} + y_2 \mathbf{x}_2 = (0, -1, -1)^T$$

$$\text{sign}(\mathbf{w}_{[1,2]}^{(2)T} \mathbf{x}_1) = 0 \neq y_1, \therefore \mathbf{w}_{[1,2]}^{(3)} = \mathbf{w}_{[1,2]}^{(2)} + y_1 \mathbf{x}_1 = (1, -1, -1)^T$$

$$\text{sign}(\mathbf{w}_{[1,2]}^{(3)T} \mathbf{x}_2) = -1 = y_2, \text{ 且 } \text{sign}(\mathbf{w}_{[1,2]}^{(3)T} \mathbf{x}_1) = 1 = y_1$$

$$\therefore \mathbf{w}_{[1,2]} = (1, -1, -1)^T, \text{ 分类面为: } 1 - x_1 - x_2 = 0$$

(2) 用感知器算法求第一类和第三类之间的分类面

样本增广后为: $\mathbf{x}_1 = (1,0,0)^T$, $y_1 = 1$, $\mathbf{x}_3 = (1,-1,1)^T$, $y_3 = -1$,

初始化权重: $\mathbf{w}_{[1,3]}^{(0)} = (0,0,0)^T$

$$\text{sign}(\mathbf{w}_{[1,3]}^{(0)T} \mathbf{x}_1) = 0 \neq y_1, \therefore \mathbf{w}_{[1,3]}^{(1)} = \mathbf{w}_{[1,3]}^{(0)} + y_1 \mathbf{x}_1 = (1,0,0)^T,$$

$$\text{sign}(\mathbf{w}_{[1,3]}^{(1)T} \mathbf{x}_3) = 1 \neq y_3, \therefore \mathbf{w}_{[1,3]}^{(2)} = \mathbf{w}_{[1,3]}^{(1)} + y_3 \mathbf{x}_3 = (0, 1, -1)^T$$

$$\text{sign}(\mathbf{w}_{[1,3]}^{(2)T} \mathbf{x}_1) = 0 \neq y_1, \therefore \mathbf{w}_{[1,3]}^{(3)} = \mathbf{w}_{[1,3]}^{(2)} + y_1 \mathbf{x}_1 = (1, 1, -1)^T$$

$$\text{sign}(\mathbf{w}_{[1,3]}^{(3)T} \mathbf{x}_3) = -1 = y_3, \text{ 且 } \text{sign}(\mathbf{w}_{[1,3]}^{(3)T} \mathbf{x}_1) = 1 = y_1$$

$\therefore \mathbf{w}_{[1,3]} = (1, 1, -1)^T$, 分类面为: $1 + x_1 - x_2 = 0$

(3) 用感知器算法求第二类和第三类之间的分类面

样本增广后为: $\mathbf{x}_2 = (1, 1, 1)^T$, $y_2 = 1$, $\mathbf{x}_3 = (1, -1, 1)^T$, $y_3 = -1$,

初始化权重: $\mathbf{w}_{[2,3]}^{(0)} = (0, 0, 0)^T$

$\text{sign}(\mathbf{w}_{[2,3]}^{(0)T} \mathbf{x}_2) = 0 \neq y_2$, $\therefore \mathbf{w}_{[2,3]}^{(1)} = \mathbf{w}_{[2,3]}^{(0)} + y_2 \mathbf{x}_2 = (1, 1, 1)^T$,

$\text{sign}(\mathbf{w}_{[2,3]}^{(1)T} \mathbf{x}_3) = 1 \neq y_3$, $\therefore \mathbf{w}_{[2,3]}^{(2)} = \mathbf{w}_{[2,3]}^{(1)} + y_3 \mathbf{x}_3 = (0, 2, 0)^T$

$\text{sign}(\mathbf{w}_{[2,3]}^{(2)T} \mathbf{x}_2) = 1 = y_2$, 且 $\text{sign}(\mathbf{w}_{[2,3]}^{(2)T} \mathbf{x}_3) = -1 = y_3$

$\therefore \mathbf{w}_{[2,3]} = (0, 2, 0)^T$, 分类面为: $x_1 = 0$

对测试样本进行增广, $\mathbf{x} = (1, 1, -2)^T$, 分别代入上述三个分类面:

第一类和第二类:

$\text{sign}(\mathbf{w}_{[1,2]}^T \mathbf{x}) = \text{sign}((1, -1, -1)(1, 1, -2)^T) = 1$, $\therefore \mathbf{x} \in \text{第一类}$

第一类和第三类:

$\text{sign}(\mathbf{w}_{[1,3]}^T \mathbf{x}) = \text{sign}((1, 1, -1)(1, 1, -2)^T) = 1$, $\therefore \mathbf{x} \in \text{第一类}$

第二类和第三类:

$\text{sign}(\mathbf{w}_{[2,3]}^T \mathbf{x}) = \text{sign}((0, 2, 0)(1, 1, -2)^T) = 1$, $\therefore \mathbf{x} \in \text{第二类}$

最终的投票结果是测试样本属于第一类。

2, 现有四个样本, 假设样本 (3, 0) 和 (3, 6) 属于第一类, 样本 (0, 3) 属于第二类, 样本 (-3, 0) 属于第三类, 请用 Softmax 算法设计出这三个类别的分类器(假设这三个类别的初始权向量均为零向量, 迭代步长取 1, 需要写出计算过程)。

解：

(1) 梯度的计算

假设输入样本 $\mathbf{x}$ 属于 K 个类别 $Y = \{1, 2, \dots, k, \dots, K\}$ 中的某个类别 k 时，在Softmax中，我们按照式（1）计算其内积，按照式（2）计算其属于类别 j 的概率：

$$s_j = \mathbf{w}_j^T \mathbf{x} \quad (1)$$

$$\hat{y}_j = \frac{e^{s_j}}{\sum_k e^{s_k}} \quad (2)$$

经过Softmax函数后，得到的输出为 K 个类别的概率列向量： $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_j, \dots, \hat{y}_K)^T$ ，假设理想的各个类别标签对应的概率为列向量： $\mathbf{y} = \{y_1, \dots, y_j, \dots, y_K\}$ ，且该列向量的一个元素为1，其他均为0，代表样本属于这个类别。我们选择用交叉熵作为误差函数其表达式为：

$$L_{in}(\mathbf{w}_k) = -\sum_{k=1}^K y_k \ln \hat{y}_k = -\ln \hat{y}_k \quad (3)$$

我们可以计算 L_{in} 对于 $\mathbf{w}_j$ ($j = 1, 2, \dots, K$)的梯度：

$$\frac{\partial L_{in}}{\partial \mathbf{w}_j} = \frac{\partial L_{in}}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial s_j} \frac{\partial s_j}{\partial \mathbf{w}_j} = -\frac{1}{\hat{y}_k} \frac{\partial \hat{y}_k}{\partial s_j} \mathbf{x}^T \quad (4)$$

我们再来计算 $\frac{\partial \hat{y}_k}{\partial s_j}$ ：

$$\begin{aligned} \frac{\partial \hat{y}_k}{\partial s_j} &= \frac{\partial}{\partial s_j} \left(\frac{e^{s_k}}{\sum_k e^{s_k}} \right) = \frac{(e^{s_k})' \sum_k e^{s_k} - (\sum_k e^{s_k})' e^{s_k}}{(\sum_k e^{s_k})^2} = \\ &\begin{cases} \frac{e^{s_j} \sum_k e^{s_k} - e^{s_j} e^{s_k}}{(\sum_k e^{s_k})^2} = \frac{e^{s_j}}{\sum_k e^{s_k}} - \frac{e^{s_j} e^{s_k}}{\sum_k e^{s_k} \sum_k e^{s_k}} = \hat{y}_j (1 - \hat{y}_k) & j = k \\ \frac{0 \sum_k e^{s_k} - e^{s_j} e^{s_k}}{(\sum_k e^{s_k})^2} = 0 - \frac{e^{s_j} e^{s_k}}{\sum_k e^{s_k} \sum_k e^{s_k}} = -\hat{y}_k \hat{y}_j & j \neq k \end{cases} \quad (5) \end{aligned}$$

将式（5）代入到式（4），我们得到 E_{in} 对于 $\mathbf{w}_j$ 的梯度：

$$\frac{\partial L_{in}}{\partial \mathbf{w}_j} = \frac{\partial L_{in}}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial s_j} \frac{\partial s_j}{\partial \mathbf{w}_j} = -\frac{1}{\hat{y}_k} \frac{\partial \hat{y}_k}{\partial s_j} \mathbf{x}^T = \begin{cases} (\hat{y}_j - 1) \mathbf{x}^T & j = k \\ \hat{y}_j \mathbf{x}^T & j \neq k \end{cases} \quad (6)$$

针对 N 个训练样本，将上述推导及求解过程写成矩阵或向量形式如下：

假设训练样本集有N个样本 $\{\mathbf{x}_1, \dots, \mathbf{x}_n, \dots, \mathbf{x}_N\}$ ，每个样本有d维特征，写成增广向量后是d+1维， $\mathbf{x}_n = (x_{n0}, x_{n1}, \dots, x_{nd})^T$ ，所有的训练样本我们用 $\mathbf{X}$ 来表示成一个N*(d+1)维的矩阵：

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_{10} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{N0} & \cdots & x_{Nd} \end{pmatrix} \quad (7)$$

所有训练样本标签对应的概率输出用N*K维矩阵表示，其中K是类别数，样本只能属于其中一个类别且概率取1，其他类别概率为0，假设如下表示的第一个样本属于类别1，第N个样本属于类别K：

$$\mathbf{Y} = \begin{pmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_n \\ \vdots \\ \mathbf{y}_N \end{pmatrix} = \begin{pmatrix} y_{11} & \cdots & y_{1K} \\ \vdots & \ddots & \vdots \\ y_{N1} & \cdots & y_{NK} \end{pmatrix} = \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix} \quad (8)$$

经过式(1)、式(2)后，我们得到的样本类别的概率估计值为N*K维矩阵 $\hat{\mathbf{Y}}$ ：

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{\mathbf{y}}_1 \\ \vdots \\ \hat{\mathbf{y}}_n \\ \vdots \\ \hat{\mathbf{y}}_N \end{pmatrix} = \begin{pmatrix} \hat{y}_{11} & \cdots & \hat{y}_{1K} \\ \vdots & \ddots & \vdots \\ \hat{y}_{N1} & \cdots & \hat{y}_{NK} \end{pmatrix} \quad (9)$$

根据式 (6) 得到 L_{in} 的梯度可以写为：

$$\nabla L_{in} = (\hat{\mathbf{Y}} - \mathbf{Y})^T \mathbf{X} = (\hat{\mathbf{y}}_1 - \mathbf{y}_1, \dots, \hat{\mathbf{y}}_n - \mathbf{y}_n, \dots, \hat{\mathbf{y}}_N - \mathbf{y}_N) \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} \sum_{n=1}^N (\hat{y}_{n1} - y_{n1}) \mathbf{x}_n^T \\ \vdots \\ \sum_{n=1}^N (\hat{y}_{nj} - y_{nj}) \mathbf{x}_n^T \\ \vdots \\ \sum_{n=1}^N (\hat{y}_{nK} - y_{nK}) \mathbf{x}_n^T \end{pmatrix} \quad (10)$$

这相当于K*N维的矩阵与N*(d+1)维的矩阵做内积，得到K*(d+1)维的梯度，这里 y_{nj} 只会取0或者1。

假设类别对应的权系数向量用 $\mathbf{w}$ 表示，加上常数项，它也是(d+1)维，一共K个类别，可以写成(d+1)*K维矩阵形式：

$$\mathbf{W} = (\mathbf{w}_1 \quad \cdots \quad \mathbf{w}_j \quad \cdots \quad \mathbf{w}_K) = \begin{pmatrix} w_{01} & \cdots & w_{0K} \\ \vdots & \ddots & \vdots \\ w_{d1} & \cdots & w_{dK} \end{pmatrix} \quad (11)$$

假设学习率为 η ，迭代次数用上标 t 表示，利用梯度下降法得到权重的更新式：

$$\mathbf{w}^{T(t+1)} = \mathbf{w}^{T(t)} - \eta \nabla L_{in} = \begin{pmatrix} \mathbf{w}_1^{(t)} - \eta \sum_{n=1}^N (\hat{y}_{n1} - y_{n1}) \mathbf{x}_n^T \\ \vdots \\ \mathbf{w}_j^{(t)} - \eta \sum_{n=1}^N (\hat{y}_{nj} - y_{nj}) \mathbf{x}_n^T \\ \vdots \\ \mathbf{w}_K^{(t)} - \eta \sum_{n=1}^N (\hat{y}_{nK} - y_{nK}) \mathbf{x}_n^T \end{pmatrix} \quad (12)$$

根据更新后的权重，我们可以重新计算每个样本在每个类别权系数向量下的内积 S ，同样，我们也可以把 S 写成矩阵形式，它是 $N \times K$ 维矩阵：

$$\mathbf{S} = \mathbf{XW}^{(t+1)} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} (\mathbf{w}_1^{(t+1)}, \dots, \mathbf{w}_j^{(t+1)}, \dots, \mathbf{w}_K^{(t+1)}) = \begin{pmatrix} (\mathbf{w}_1^{(t+1)})^T \mathbf{x}_1 & \cdots & (\mathbf{w}_K^{(t+1)})^T \mathbf{x}_1 \\ \vdots & \ddots & \vdots \\ (\mathbf{w}_1^{(t+1)})^T \mathbf{x}_N & \cdots & (\mathbf{w}_K^{(t+1)})^T \mathbf{x}_N \end{pmatrix} = \begin{pmatrix} s_{11} & \cdots & s_{1j} & \cdots & s_{1K} \\ \vdots & \cdots & \vdots & \cdots & \vdots \\ s_{n1} & \cdots & s_{nj} & \cdots & s_{nK} \\ \vdots & \cdots & \vdots & \cdots & \vdots \\ s_{N1} & \cdots & s_{Nj} & \cdots & s_{NK} \end{pmatrix} \quad (13)$$

利用Softmax可以得到：

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_n \\ \vdots \\ \hat{y}_N \end{pmatrix} = \begin{pmatrix} \hat{y}_{11} & \cdots & \hat{y}_{1K} \\ \vdots & \ddots & \vdots \\ \hat{y}_{N1} & \cdots & \hat{y}_{NK} \end{pmatrix} \quad (14)$$

因为对于一个样本的误差函数为式（3），所以，对于所有样本其误差函数（损失函数）为：

$$L_{in} = \frac{1}{N} \sum_{n=1}^N (-\ln \hat{y}_{nk}) \quad (15)$$

（2）习题的求解

首先，将样本变为增广向量： $\mathbf{x}_1 = (1, 3, 0)^T$, $\mathbf{x}_2 = (1, 3, 6)^T$, $\mathbf{x}_3 = (1, 0, 3)^T$, $\mathbf{x}_4 =$

$(1, -3, 0)^T$, 得到:

$$\mathbf{X} = \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix}$$

四个样本对应的理想概率值为 $\mathbf{y}_1 = (1, 0, 0)^T$, $\mathbf{y}_2 = (1, 0, 0)^T$, $\mathbf{y}_3 = (0, 1, 0)^T$, $\mathbf{y}_4 = (0, 0, 1)^T$, 即:

$$\mathbf{Y} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

假设三个类别的初始权向量为: $\mathbf{w}_1^{(0)} = (0, 0, 0)^T$, $\mathbf{w}_2^{(0)} = (0, 0, 0)^T$, $\mathbf{w}_3^{(0)} = (0, 0, 0)^T$, 即:

$$\mathbf{W}^{(0)} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

令 $\eta = 1$ 。

第一次迭代: $t=0$, 将 $\mathbf{x}_n$, ($n = 1, 2, 3, 4$), $\mathbf{w}_k^{(0)}$, ($k = 1, 2, 3$)代入到式 (13), 得到:

$$\mathbf{S} = \mathbf{XW}^{(0)} = \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

利用式(2)和式(14)得到:

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{\mathbf{y}}_1 \\ \hat{\mathbf{y}}_2 \\ \hat{\mathbf{y}}_3 \\ \hat{\mathbf{y}}_4 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{pmatrix}$$

显然所有样本都没有正确分类, 按照式(15), 每一个样本任意选择一个类别获得

其概率, 计算 $L_{in} = \frac{1}{4} \sum_{n=1}^4 (-\ln \frac{1}{3}) = 1.099$

所以, 我们按照式 (10) 求得梯度:

$$\nabla L_{in} = (\hat{\mathbf{Y}} - \mathbf{Y})^T \mathbf{X} = \begin{pmatrix} \frac{1}{3} - 1 & \frac{1}{3} - 1 & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} - 1 & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} - 1 \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} & \frac{1}{3} - 1 \end{pmatrix} \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} = \begin{pmatrix} -\frac{2}{3} & -5 & -3 \\ \frac{1}{3} & 1 & 0 \\ \frac{1}{3} & 1 & 0 \\ \frac{1}{3} & 4 & 3 \end{pmatrix}$$

用梯度下降法式(12)进行权系数向量更新:

$$\mathbf{w}^{T(1)} = \mathbf{w}^{T(0)} - \eta \nabla L_{in} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} - \begin{pmatrix} -\frac{2}{3} & -5 & -3 \\ \frac{1}{3} & 1 & 0 \\ \frac{1}{3} & 4 & 3 \end{pmatrix} = \begin{pmatrix} \frac{2}{3} & 5 & 3 \\ -\frac{1}{3} & -1 & 0 \\ -\frac{1}{3} & -4 & -3 \end{pmatrix}$$

根据式(13)得到S矩阵:

$$\mathbf{S} = \mathbf{XW}^{(1)} = \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \begin{pmatrix} \frac{2}{3} & -\frac{1}{3} & -\frac{1}{3} \\ 5 & -1 & -4 \\ 3 & 0 & -3 \end{pmatrix} = \begin{pmatrix} 15.67 & -3.33 & -12.33 \\ 33.67 & -3.33 & -30.33 \\ 9.67 & -0.33 & -9.33 \\ -14.33 & 2.67 & 11.67 \end{pmatrix}$$

利用Softmax得到:

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{\mathbf{y}}_1 \\ \hat{\mathbf{y}}_2 \\ \hat{\mathbf{y}}_3 \\ \hat{\mathbf{y}}_4 \end{pmatrix} = \begin{pmatrix} 1.00 & 0.00 & 0.00 \\ 1.00 & 0.00 & 0.00 \\ 1.00 & 0.00 & 0.00 \\ 0.00 & 0.00 & 1.00 \end{pmatrix}$$

第三个样本错分, 计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0 - \ln 1)/4 = \infty$

第二次迭代:

我们按照式 (10) 求得梯度:

$$\nabla L_{in} = (\hat{\mathbf{Y}} - \mathbf{Y})^T \mathbf{X} = \begin{pmatrix} 1-1 & 1-1 & 1 & 0 \\ 0 & 0 & 0-1 & 0 \\ 0 & 0 & 0 & 1-1 \end{pmatrix} \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 3 \\ -1 & 0 & -3 \\ 0 & 0 & 0 \end{pmatrix}$$

用梯度下降法式(12)进行权系数向量更新:

$$\begin{aligned}\mathbf{w}^{T(2)} &= \mathbf{w}^{T(1)} - \eta \nabla L_{in} = \begin{pmatrix} \frac{2}{3} & 5 & 3 \\ -\frac{1}{3} & -1 & 0 \\ -\frac{1}{3} & -4 & -3 \end{pmatrix} - \begin{pmatrix} 1 & 0 & 3 \\ -1 & 0 & -3 \\ 0 & 0 & 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.33 & 5 & 0 \\ 0.67 & -1 & 3 \\ -0.33 & -4 & -3 \end{pmatrix}\end{aligned}$$

根据式(13)得到S矩阵:

$$\mathbf{S} = \mathbf{XW}^{(2)} = \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \begin{pmatrix} -0.33 & 0.67 & -0.33 \\ 5 & -1 & -4 \\ 0 & 3 & -3 \end{pmatrix} = \begin{pmatrix} 14.67 & -2.33 & -12.33 \\ 14.67 & 15.67 & -30.33 \\ -0.33 & 9.67 & -9.33 \\ -15.33 & 3.67 & 11.27 \end{pmatrix}$$

利用Softmax得到:

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \hat{y}_4 \end{pmatrix} = \begin{pmatrix} 1.00 & 0.00 & 0.00 \\ 0.27 & 0.73 & 0.00 \\ 0.00 & 1.00 & 0.00 \\ 0.00 & 0.00 & 1.00 \end{pmatrix}$$

第二个样本错分, 计算 $L_{in} = (-\ln 1 - \ln 0.27 - \ln 1 - \ln 1)/4 = 0.33$

第三次迭代:

我们按照式 (10) 求得梯度:

$$\begin{aligned}\nabla L_{in} &= (\hat{\mathbf{Y}} - \mathbf{Y})^T \mathbf{X} = \begin{pmatrix} 1-1 & 0.27-1 & 0 & 0 \\ 0 & 0.73 & 1-1 & 0 \\ 0 & 0 & 0 & 1-1 \end{pmatrix} \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.73 & -2.19 & -4.38 \\ 0.73 & 2.19 & 4.38 \\ 0 & 0 & 0 \end{pmatrix}\end{aligned}$$

用梯度下降法式(12)进行权系数向量更新:

$$\begin{aligned}\mathbf{w}^{T(3)} &= \mathbf{w}^{T(2)} - \eta \nabla L_{in} = \begin{pmatrix} -0.33 & 5 & 0 \\ 0.67 & -1 & 3 \\ -0.33 & -4 & -3 \end{pmatrix} - \begin{pmatrix} -0.73 & -2.19 & -4.38 \\ 0.73 & 2.19 & 4.38 \\ 0 & 0 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 0.40 & 7.19 & 4.38 \\ -0.06 & -3.19 & -1.38 \\ -0.33 & -4 & -3 \end{pmatrix}\end{aligned}$$

根据式(13)得到S矩阵:

$$\mathbf{S} = \mathbf{XW}^{(3)} =$$

$$\begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \begin{pmatrix} 0.40 & -0.06 & -0.33 \\ 7.19 & -3.19 & -4 \\ 4.38 & -1.38 & -3 \end{pmatrix} = \begin{pmatrix} 21.97 & -9.63 & -12.33 \\ 48.25 & -17.91 & -30.33 \\ 13.54 & -4.20 & -9.33 \\ -21.17 & 9.51 & 11.67 \end{pmatrix}$$

利用Softmax得到:

$$\hat{\mathbf{Y}} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \hat{y}_4 \end{pmatrix} = \begin{pmatrix} 1.00 & 0.00 & 0.00 \\ 1.00 & 0.00 & 0.00 \\ 1.00 & 0.00 & 0.00 \\ 0.00 & 0.11 & 0.89 \end{pmatrix}$$

第三个样本错分, 计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0 - \ln 0.89)/4 = \infty$

第四次迭代:

我们按照式 (10) 求得梯度:

$$\begin{aligned} \nabla L_{in} &= (\hat{\mathbf{Y}} - \mathbf{Y})^T \mathbf{X} = \begin{pmatrix} 1-1 & 1-1 & 1 & 0 \\ 0 & 0 & 0-1 & 0.11 \\ 0 & 0 & 0 & 0.89-1 \end{pmatrix} \begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 & 3 \\ -0.89 & -0.33 & -3 \\ -0.11 & 0.33 & 0 \end{pmatrix} \end{aligned}$$

用梯度下降法式(12)进行权系数向量更新:

$$\begin{aligned} \mathbf{w}^{T(4)} &= \mathbf{w}^{T(3)} - \eta \nabla L_{in} = \begin{pmatrix} 0.40 & 7.19 & 4.38 \\ -0.06 & -3.19 & -1.38 \\ -0.33 & -4 & -3 \end{pmatrix} - \begin{pmatrix} 1 & 0 & 3 \\ -0.89 & -0.33 & -3 \\ -0.11 & 0.33 & 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.60 & 7.19 & 1.38 \\ 0.83 & -2.86 & 1.62 \\ -0.22 & -4.33 & -3 \end{pmatrix} \end{aligned}$$

根据式(13)得到S矩阵:

$$\mathbf{S} = \mathbf{XW}^{(4)} =$$

$$\begin{pmatrix} 1 & 3 & 0 \\ 1 & 3 & 6 \\ 1 & 0 & 3 \\ 1 & -3 & 0 \end{pmatrix} \begin{pmatrix} -0.60 & 0.83 & -0.22 \\ 7.19 & -2.86 & -4.33 \\ 1.38 & 1.62 & -3 \end{pmatrix} = \begin{pmatrix} 20.97 & -7.75 & -13.21 \\ 29.25 & 1.97 & -31.21 \\ 3.54 & 5.69 & -9.22 \\ -22.17 & 9.41 & 12.77 \end{pmatrix}$$

利用Softmax得到:

$$\hat{Y} = \begin{pmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \hat{y}_4 \end{pmatrix} = \begin{pmatrix} 1.00 & 0.00 & 0.00 \\ 1.00 & 0.00 & 0.00 \\ 0.10 & 0.90 & 0.00 \\ 0.00 & 0.02 & 0.98 \end{pmatrix}$$

所有样本均正确分类，计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0.90 - \ln 0.98)/4 = 0.03$

此时求得的权系数向量矩阵为：

$$\mathbf{W}^{(4)} = \begin{pmatrix} -0.60 & 0.83 & -0.22 \\ 7.19 & -2.86 & -4.33 \\ 1.38 & 1.62 & -3 \end{pmatrix}$$

即：

$$\mathbf{w}_1 = (-0.60, 7.19, 1.38)^T$$

$$\mathbf{w}_2 = (0.83, -2.86, 1.62)^T$$

$$\mathbf{w}_3 = (-0.22, -4.33, -3)^T$$

不习惯看矩阵的，可以看如下求解过程：

第一次迭代：将 $\mathbf{x}_n$, ($n = 1, 2, 3, 4$), $\mathbf{w}_k^{(0)}$, ($k = 1, 2, 3$) 代入到式 (1)，对每一个样

本均得到 $s_1 = s_2 = s_3 = 0$ ，代入式 (2) 得到： $\hat{Y} = (\hat{y}_1, \hat{y}_2, \hat{y}_3)^T = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})^T$ ，

显然这个样本没有正确分类，所以，我们按照式 (6) 求得梯度去计算新的 $\mathbf{w}_k$ ，

我们以计算 $\mathbf{w}_1$ 为例，先用式 (6) 计算梯度：

$$\begin{aligned} \frac{\partial L_{in}}{\partial \mathbf{w}_1} &= \sum_{n=1}^4 \frac{\partial L_{in}(\mathbf{x}_n)}{\partial \mathbf{w}_1} = (\hat{y}_1 - 1)\mathbf{x}_1^T + (\hat{y}_1 - 1)\mathbf{x}_2^T + \hat{y}_2\mathbf{x}_3^T + \hat{y}_3\mathbf{x}_4^T \\ &= \left(\frac{1}{3} - 1\right)\mathbf{x}_1^T + \left(\frac{1}{3} - 1\right)\mathbf{x}_2^T + \frac{1}{3}\mathbf{x}_3^T + \frac{1}{3}\mathbf{x}_4^T = \left(-\frac{2}{3}, -5, -3\right)^T \end{aligned}$$

同理，我们可以得到： $\frac{\partial L_{in}}{\partial \mathbf{w}_2} = (\frac{1}{3}, 1, 0)^T$ ， $\frac{\partial L_{in}}{\partial \mathbf{w}_3} = (\frac{1}{3}, 4, 3)^T$

用梯度下降法对 $\mathbf{w}_k$ 进行更新：

$$\mathbf{w}_1^{(1)} = \mathbf{w}_1^{(0)} - \frac{\partial L_{in}}{\partial \mathbf{w}_1} = (0,0,0)^T - \left(-\frac{2}{3}, -5, -3\right)^T = \left(\frac{2}{3}, 5, 3\right)^T$$

$$\mathbf{w}_2^{(1)} = \mathbf{w}_2^{(0)} - \frac{\partial L_{in}}{\partial \mathbf{w}_2} = (0,0,0)^T - \left(\frac{1}{3}, 1, 0\right)^T = \left(-\frac{1}{3}, -1, 0\right)^T$$

$$\mathbf{w}_3^{(1)} = \mathbf{w}_3^{(0)} - \frac{\partial L_{in}}{\partial \mathbf{w}_3} = (0,0,0)^T - \left(\frac{1}{3}, 4, 3\right)^T = \left(-\frac{1}{3}, -4, -3\right)^T$$

根据 $\mathbf{w}_1^{(1)}$ ， $\mathbf{w}_2^{(1)}$ 和 $\mathbf{w}_3^{(1)}$ ，我们用式（1）得到：

$$\begin{aligned} \text{对于 } \mathbf{x}_1, \text{ 我们有: } s_1 &= \mathbf{w}_1^T \mathbf{x}_1 = \left(\frac{2}{3}, 5, 3\right) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = 15.67, \quad s_2 = \mathbf{w}_2^T \mathbf{x}_1 = \\ &\left(-\frac{1}{3}, -1, 0\right) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -3.33, \quad s_3 = \mathbf{w}_3^T \mathbf{x}_1 = \left(-\frac{1}{3}, -4, -3\right) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -12.33 \end{aligned}$$

利用式（2），我们可以得到： $\hat{y}_1 = \frac{e^{s_1}}{e^{s_1}+e^{s_2}+e^{s_3}} = 1.00$ ， $\hat{y}_2 = \frac{e^{s_2}}{e^{s_1}+e^{s_2}+e^{s_3}} = 0.00$ ， $\hat{y}_3 = \frac{e^{s_3}}{e^{s_1}+e^{s_2}+e^{s_3}} = 0.00$ ，即， $\hat{\mathbf{y}}_1 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_1 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_1$ 分类是正确的。

同理：对于 $\mathbf{x}_2$ ，我们有 $s_1 = 33.67$ ， $s_2 = -3.33$ ， $s_3 = -30.33$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_2 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_2 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_2$ 分类是正确的。

对于 $\mathbf{x}_3$ ，我们有 $s_1 = 9.67$ ， $s_2 = -0.33$ ， $s_3 = -9.33$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_3 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_3 = (0, 1, 0)^T$ ，此时对于样本 $\mathbf{x}_3$ 分类是错误的。

对于 $\mathbf{x}_4$ ，我们有 $s_1 = -14.33$ ， $s_2 = 2.67$ ， $s_3 = 11.67$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_4 = (0.00, 0.00, 1.00)^T$ ，对照 $\mathbf{y}_4 = (0, 0, 1)^T$ ，此时对于样本 $\mathbf{x}_4$ 分类是正确的。

第三个样本错分，计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0 - \ln 1)/4 = \infty$

第二次迭代：我们需要按照式（6）重新计算梯度去得到新的 $\mathbf{w}_k$ ，仍以计算 $\mathbf{w}_1$ 为

例，先用式（6）计算梯度：

$$\begin{aligned}\frac{\partial L_{in}}{\partial \mathbf{w}_1} &= \sum_{n=1}^4 \frac{\partial L_{in}(\mathbf{x}_n)}{\partial \mathbf{w}_1} = (\hat{y}_1 - 1)\mathbf{x}_1^T + (\hat{y}_1 - 1)\mathbf{x}_2^T + \hat{y}_2\mathbf{x}_3^T + \hat{y}_3\mathbf{x}_4^T \\ &= (1 - 1)\mathbf{x}_1^T + (1 - 1)\mathbf{x}_2^T + 1\mathbf{x}_3^T + 0\mathbf{x}_4^T = (1, 0, 3)^T\end{aligned}$$

同理，我们可以得到： $\frac{\partial L_{in}}{\partial \mathbf{w}_2} = 0\mathbf{x}_1^T + 0\mathbf{x}_2^T + (0 - 1)\mathbf{x}_3^T + 0\mathbf{x}_4^T = (-1, 0, -3)^T$ ，

$$\frac{\partial L_{in}}{\partial \mathbf{w}_3} = 0\mathbf{x}_1^T + 0\mathbf{x}_2^T + 0\mathbf{x}_3^T + (1 - 1)\mathbf{x}_4^T = (0, 0, 0)^T$$

用梯度下降法对 $\mathbf{w}_k$ 进行更新：

$$\mathbf{w}_1^{(2)} = \mathbf{w}_1^{(1)} - \frac{\partial L_{in}}{\partial \mathbf{w}_1} = (0.67, 5, 3)^T - (1, 0, 3)^T = (-0.33, 5, 0)^T$$

$$\mathbf{w}_2^{(2)} = \mathbf{w}_2^{(1)} - \frac{\partial L_{in}}{\partial \mathbf{w}_2} = (-0.33, -1, 0)^T - (-1, 0, -3)^T = (0.67, -1, 3)^T$$

$$\mathbf{w}_3^{(2)} = \mathbf{w}_3^{(1)} - \frac{\partial L_{in}}{\partial \mathbf{w}_3} = (-0.33, -4, -3)^T - (0, 0, 0)^T = (-0.33, -4, -3)^T$$

根据 $\mathbf{w}_1^{(2)}$ ， $\mathbf{w}_2^{(2)}$ 和 $\mathbf{w}_3^{(2)}$ ，我们用式（1）得到：

$$\text{对于 } \mathbf{x}_1, \text{ 我们有: } s_1 = \bar{\mathbf{w}}_1^T \mathbf{x}_1 = (-0.33, 5, 0) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = 14.67, \quad s_2 = \mathbf{w}_2^T \mathbf{x}_1 =$$

$$(0.67, -1, 3) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -2.33, \quad s_3 = \mathbf{w}_3^T \mathbf{x}_1 = (-0.33, -4, -3) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -12.33$$

利用式（2），我们可以得到： $\hat{y}_1 = \frac{e^{s_1}}{e^{s_1} + e^{s_2} + e^{s_3}} = 1.00$ ， $\hat{y}_2 = \frac{e^{s_2}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.00$ ， $\hat{y}_3 = \frac{e^{s_3}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.00$ ，即， $\hat{\mathbf{y}}_1 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_1 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_1$ 分类是正确的。

同理：对于 $\mathbf{x}_2$ ，我们有 $s_1 = 14.67$ ， $s_2 = 15.67$ ， $s_3 = -30.33$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_2 = (0.27, 0.73, 0.00)^T$ ，对照 $\mathbf{y}_2 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_2$ 分类是错误的。

对于 $\mathbf{x}_3$ ，我们有 $s_1 = -0.33$ ， $s_2 = 9.67$ ， $s_3 = -9.33$ ，对应的我们可以计算

出 $\hat{\mathbf{y}}_3 = (0.00, 1.00, 0.00)^T$ ，对照 $\mathbf{y}_3 = (0, 1, 0)^T$ ，此时对于样本 $\mathbf{x}_3$ 分类是正确的。

对于 $\mathbf{x}_4$ ，我们有 $s_1 = -15.33$ ， $s_2 = 3.67$ ， $s_3 = 11.27$ ，对应的我们可以计

算出 $\hat{\mathbf{y}}_4 = (0.00, 0.00, 1.00)^T$ ，对照 $\mathbf{y}_4 = (0, 0, 1)^T$ ，此时对于样本 $\mathbf{x}_4$ 分类是正确的。

第二个样本错分，计算 $L_{in} = (-\ln 1 - \ln 0.27 - \ln 1 - \ln 1)/4 = 0.33$

第三次迭代：我们需要按照式（6）重新计算梯度去得到新的 $\mathbf{w}_k$ ，仍以计算 $\mathbf{w}_1$ 为

例，先用式（6）计算梯度：

$$\begin{aligned}\frac{\partial L_{in}}{\partial \mathbf{w}_1} &= \sum_{n=1}^4 \frac{\partial L_{in}(\mathbf{x}_n)}{\partial \mathbf{w}_1} = (\hat{y}_1 - 1)\mathbf{x}_1^T + (\hat{y}_1 - 1)\mathbf{x}_2^T + \hat{y}_2\mathbf{x}_3^T + \hat{y}_3\mathbf{x}_4^T \\ &= (1 - 1)\mathbf{x}_1^T + (0.27 - 1)\mathbf{x}_2^T + 0\mathbf{x}_3^T + 0\mathbf{x}_4^T \\ &= (-0.73, -2.19, -4.38)^T\end{aligned}$$

同理，我们可以得到： $\frac{\partial L_{in}}{\partial \mathbf{w}_2} = 0\mathbf{x}_1^T + 0.73\mathbf{x}_2^T + (1 - 1)\mathbf{x}_3^T + 0\mathbf{x}_4^T = (0.73, 2.19, 4.38)^T$ ， $\frac{\partial L_{in}}{\partial \mathbf{w}_3} = 0\mathbf{x}_1^T + 0\mathbf{x}_2^T + 0\mathbf{x}_3^T + (1 - 1)\mathbf{x}_4^T = (0, 0, 0)^T$

用梯度下降法对 $\mathbf{w}_k$ 进行更新：

$$\begin{aligned}\mathbf{w}_1^{(3)} &= \mathbf{w}_1^{(2)} - \frac{\partial L_{in}}{\partial \mathbf{w}_1} = (-0.33, 5, 0)^T - (-0.73, -2.19, -4.38)^T \\ &= (0.40, 7.19, 4.38)^T \\ \mathbf{w}_2^{(3)} &= \mathbf{w}_2^{(2)} - \frac{\partial L_{in}}{\partial \mathbf{w}_2} = (0.67, -1, 3)^T - (0.73, 2.19, 4.38)^T \\ &= (-0.06, -3.19, -1.38)^T \\ \mathbf{w}_3^{(3)} &= \mathbf{w}_3^{(2)} - \frac{\partial L_{in}}{\partial \mathbf{w}_3} = (-0.33, -4, -3)^T - (0, 0, 0)^T = (-0.33, -4, -3)^T\end{aligned}$$

根据 $\mathbf{w}_1^{(3)}$ ， $\mathbf{w}_2^{(3)}$ 和 $\mathbf{w}_3^{(3)}$ ，我们用式（1）得到：

$$\text{对于}\mathbf{x}_1, \text{我们有: } s_1 = \mathbf{w}_1^T \mathbf{x}_1 = (0.40, 7.19, 4.38) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = 21.97, \quad s_2 = \mathbf{w}_2^T \mathbf{x}_1 =$$

$$(-0.06, -3.19, -1.38) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -9.63, \quad s_3 = \mathbf{w}_3^T \mathbf{x}_1 = (-0.33, -4, -3) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -12.33$$

利用式 (2)，我们可以得到： $\hat{y}_1 = \frac{e^{s_1}}{e^{s_1} + e^{s_2} + e^{s_3}} = 1.0000$, $\hat{y}_2 = \frac{e^{s_2}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.0000$, $\hat{y}_3 = \frac{e^{s_3}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.0000$ ，即， $\hat{\mathbf{y}}_1 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_1 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_1$ 分类是正确的。

同理：对于 $\mathbf{x}_2$ ，我们有 $s_1 = 48.25$, $s_2 = -17.91$, $s_3 = -30.33$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_2 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_2 = (1, 0, 0)^T$ ，此时对于样本 $\mathbf{x}_2$ 分类是正确的。

对于 $\mathbf{x}_3$ ，我们有 $s_1 = 13.54$, $s_2 = -4.20$, $s_3 = -9.33$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_3 = (1.00, 0.00, 0.00)^T$ ，对照 $\mathbf{y}_3 = (0, 1, 0)^T$ ，此时对于样本 $\mathbf{x}_3$ 分类是错误的。

对于 $\mathbf{x}_4$ ，我们有 $s_1 = -21.17$, $s_2 = 9.51$, $s_3 = 11.67$ ，对应的我们可以计算出 $\hat{\mathbf{y}}_4 = (0.0000, 0.11, 0.89)^T$ ，对照 $\mathbf{y}_4 = (0, 0, 1)^T$ ，此时对于样本 $\mathbf{x}_4$ 分类是正确的。

第三个样本错分，计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0 - \ln 0.89)/4 = \infty$

第四次迭代：我们需要按照式 (6) 重新计算梯度去得到新的 $\mathbf{w}_k$ ，仍以计算 $\mathbf{w}_1$ 为例，先用式 (6) 计算梯度：

$$\begin{aligned} \frac{\partial L_{in}}{\partial \mathbf{w}_1} &= \sum_{n=1}^4 \frac{\partial L_{in}(\mathbf{x}_n)}{\partial \mathbf{w}_1} = (\hat{y}_1 - 1)\mathbf{x}_1^T + (\hat{y}_1 - 1)\mathbf{x}_2^T + \hat{y}_2\mathbf{x}_3^T + \hat{y}_3\mathbf{x}_4^T \\ &= (1 - 1)\mathbf{x}_1^T + (1 - 1)\mathbf{x}_2^T + 1\mathbf{x}_3^T + 0\mathbf{x}_4^T = (1, 0, 3)^T \end{aligned}$$

同理，我们可以得到：

$$\frac{\partial L_{in}}{\partial \mathbf{w}_2} = 0\mathbf{x}_1^T + 0\mathbf{x}_2^T + (0 - 1)\mathbf{x}_3^T + 0.11\mathbf{x}_4^T = (-0.89, -0.33, -3)^T,$$

$$\frac{\partial L_{in}}{\partial \mathbf{w}_3} = 0\mathbf{x}_1^T + 0\mathbf{x}_2^T + 0\mathbf{x}_3^T + (0.89 - 1)\mathbf{x}_4^T = (-0.11, 0.33, 0)^T$$

用梯度下降法对 $\mathbf{w}_k$ 进行更新：

$$\mathbf{w}_1^{(4)} = \mathbf{w}_1^{(3)} - \frac{\partial L_{in}}{\partial \mathbf{w}_1} = (0.40, 7.19, 4.38)^T - (1, 0, 3)^T = (-0.60, 7.19, 1.38)^T$$

$$\begin{aligned}\mathbf{w}_2^{(4)} &= \mathbf{w}_2^{(3)} - \frac{\partial L_{in}}{\partial \mathbf{w}_2} = (-0.06, -3.19, -1.38)^T - (-0.89, -0.33, -3)^T \\ &= (0.83, -2.86, 1.62)^T\end{aligned}$$

$$\begin{aligned}\mathbf{w}_3^{(4)} &= \mathbf{w}_3^{(3)} - \frac{\partial L_{in}}{\partial \mathbf{w}_3} = (-0.33, -4, -3)^T - (-0.11, 0.33, 0)^T \\ &= (-0.22, -4.33, -3)^T\end{aligned}$$

根据 $\mathbf{w}_1^{(4)}$, $\mathbf{w}_2^{(4)}$ 和 $\mathbf{w}_3^{(4)}$, 我们用式 (1) 得到：

$$\begin{aligned}\text{对于 } \mathbf{x}_1, \text{ 我们有: } s_1 &= \mathbf{w}_1^T \mathbf{x}_1 = (-0.60, 7.19, 1.38) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = 20.97, \quad s_2 = \mathbf{w}_2^T \mathbf{x}_1 = \\ &(0.83, -2.86, 1.62) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = -7.75, \quad s_3 = \mathbf{w}_3^T \mathbf{x}_1 = (-0.18, -4.45, -3) \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix} = \\ &-13.21\end{aligned}$$

利用式 (2), 我们可以得到: $\hat{y}_1 = \frac{e^{s_1}}{e^{s_1} + e^{s_2} + e^{s_3}} = 1.00$, $\hat{y}_2 = \frac{e^{s_2}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.00$, $\hat{y}_3 = \frac{e^{s_3}}{e^{s_1} + e^{s_2} + e^{s_3}} = 0.00$, 即, $\hat{\mathbf{y}}_1 = (1.00, 0.00, 0.00)^T$, 对照 $\mathbf{y}_1 = (1, 0, 0)^T$, 此时对于样本 $\mathbf{x}_1$ 分类是正确的。

同理: 对于 $\mathbf{x}_2$, 我们有 $s_1 = 29.25$, $s_2 = 1.97$, $s_3 = -31.21$, 对应的我们可以计算出 $\hat{\mathbf{y}}_2 = (1.00, 0.00, 0.00)^T$, 对照 $\mathbf{y}_2 = (1, 0, 0)^T$, 此时对于样本 $\mathbf{x}_2$ 分类是正确的。

对于 $\mathbf{x}_3$, 我们有 $s_1 = 3.54$, $s_2 = 5.69$, $s_3 = -9.22$, 对应的我们可以计算出 $\hat{\mathbf{y}}_3 = (0.10, 0.90, 0.00)^T$, 对照 $\mathbf{y}_3 = (0, 1, 0)^T$, 此时对于样本 $\mathbf{x}_3$ 分类是正确的。

对于 $\mathbf{x}_4$, 我们有 $s_1 = -22.17$, $s_2 = 9.41$, $s_3 = 12.77$, 对应的我们可以计算出 $\hat{\mathbf{y}}_4 = (0.00, 0.02, 0.98)^T$, 对照 $\mathbf{y}_4 = (0, 0, 1)^T$, 此时对于样本 $\mathbf{x}_4$ 分类是正确的。

计算 $L_{in} = (-\ln 1 - \ln 1 - \ln 0.90 - \ln 0.98)/4 = 0.03$

于是我们最终得到的是:

$$\mathbf{w}_1 = (-0.60, 7.19, 1.38)^T$$

$$\mathbf{w}_2 = (0.83, -2.86, 1.62)^T$$

$$\mathbf{w}_3 = (-0.22, -4.33, -3)^T$$

Lecture10-11 作业

1, 假设 $g_0(\vec{x}) = 1$, 以下哪一组 $(\alpha_0, \alpha_1, \alpha_2)$ 允许 $G(\vec{x}) = \text{sign}(\sum_{t=0}^2 \alpha_t g_t(\vec{x}))$ 实现 $OR(g_1, g_2)$ 的功能。(a) $(-3, +1, +1)$; (b) $(-1, +1, +1)$; (c) $(+1, +1, +1)$; (d) $(+3, +1, +1)$ 。

解: $OR(g_1, g_2)$ 的关系意味着只要有一个 $g_i = 1$, 输出即为 1, 当两个都为 “-1” 时, 输出才为 -1。

根据题目条件:

(a) $G(\vec{x}) = \text{sign}(-3 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = g_2(\vec{x}) = 1$ 时, $G(\vec{x}) = -1$, 不满足定义;

(b) $G(\vec{x}) = \text{sign}(-1 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = -1, g_2(\vec{x}) = 1$, 或者 $g_1(\vec{x}) = 1, g_2(\vec{x}) = -1$ 时, $G(\vec{x}) = -1$, 不满足定义;

(c) $G(\vec{x}) = \text{sign}(1 + g_1(\vec{x}) + g_2(\vec{x}))$, $g_1(\vec{x})$ 与 $g_2(\vec{x})$ 取任意的 +1 和 -1 时, 均能满足 $OR(g_1, g_2)$ 的定义;

(d) $G(\vec{x}) = \text{sign}(3 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = g_2(\vec{x}) = -1$ 时, $G(\vec{x}) = 1$, 不满足定义。


所以, 只有(c)满足定义。

2, 在 3-5-1 的神经网络中, 网络参数有多少?

解: 在第一层 3-5 中的参数为: $(3+1 \text{ (常数项)}) * 5 = 20$; 在第二层 5-1 中的参数为 $(5+1 \text{ (常数项)}) * 1 = 6$, 所以, 网络参数一共为 26。

3, 画出 $(x+y)^2 z$ 的计算图, 当 $x=1, y=2, z=-6$ 时, 写出前向传播的数值和反向传播的梯度值。

解:




4, 计算 Sigmoid 函数、双曲正切函数和 ReLU 函数的导数函数, 分析这三个函数作为激活函数时的优缺点。

解: (1) 对于 Sigmoid 函数, $\theta(x) = \frac{1}{1+e^{-x}}$

$$\frac{\partial \theta(x)}{\partial x} = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1+e^{-x}-1}{1+e^{-x}} \cdot \frac{1}{1+e^{-x}} = (1 - \theta(x))\theta(x)$$

Sigmoid 函数作为激活函数的优点是连续、单调、可导且具有非线性特点。但其缺点是非中心对称, 输出不是 0 均值的, 同时它的导数函数曲线见右图, x 变化很小的范围内, 导数才有值且不大, 在神经




网络应用中，训练过程使用的是反向传播算法，通过链式法则回传的梯度不断相乘，因此，Sigmoid 函数作为激活函数时会导致梯度消失问题，尤其在网络比较深时会达不到训练效果。

(2) 对于双曲正切函数， $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

$$\frac{\partial \tanh(x)}{\partial x} = \frac{(e^x + e^{-x})(e^x + e^{-x}) - (e^x - e^{-x})(e^x - e^{-x})}{(e^x + e^{-x})^2} = 1 - \tanh^2(x)$$

双曲正切函数作为激活函数的优点是中心对称、单调、连续、可导且具有非线性特点。但其缺点是它的导数函数曲线见右图， x 变化更




小的范围内，导数才有值且不大于 1，在神经网络应用中，训练过程使用的是反向传播算法，通过链式法则回传的梯度不断相乘，因此，双曲正切函数作为激活函数时同样会导致梯度消失问题，尤其在网络比较深时会达不到训练效果。

(3) 对于 ReLU 函数， $ReLU(x) = \max(0, x)$

$$\frac{\partial ReLU(x)}{\partial x} = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$$

ReLU 函数作为激活函数的优点是梯度不会饱和，解决了梯度消失问题，没有指数计算，计算复杂度低。它的缺点是非中心对称，负数部分的梯度为



0，导致相应参数不会更新。

5，对于一幅 300×300 大小的彩色（RGB）图像，（1）如果输入端与有 100 个神经元的的第一层隐含层用全链接方式（Fully Connected neural Network）连接时，请问这一层会包含多少参数？（2）如果用 100 个 $5 \times 5 \times 3$ 大小的滤波器作卷积操作，那么这一层的参数为多少？如果滤波器移动步长（stride=1）为 1，经过卷积计算后的输出端神经元个数有多少？

解：（1）因为是 RGB 图像，所以共有 3 个通道，全连接情况下包含的参数是： 300×300 （图像大小） $\times 3$ （颜色通道数） $\times 100$ （第一层神经元个数） $+ 1 \times 100$ （每个神经元都要与输入层的常数项连接） $= 27000100$ ；

（2）卷积操作时，第一层的参数是由卷积滤波器大小和常数项共同确定的，因此其包含的参数为： $(5 \times 5$ （滤波器大小） $\times 3$ （颜色通道数） $+ 1$ （常数项） $) \times 100$ （滤波器个数） $= 7600$ ；（即：F=5，K=100，D1=3，参数量= $(F \times F \times D1) \times K + K = 5 \times 5 \times 3 \times 100 + 100 = 7600$ ）

因为卷积核为 $5 \times 5 \times 3$ ，且填充值为 0，卷积后第一层神经元的个数为 $((300$ （图像长或宽） $- 5$ （滤波器大小） $) / 1$ （移动步长） $) + 1$ $)^2 \times 100$ （滤波器个数） $= 8761600$ （相当于 $W1=300$ ， $H1=300$ ， $D1=3$ ， $F=5$ ， $K=100$ ， $S=1$ ， $P=0$ ， $W2 = (W1 - F + 2P) / S + 1 = (300 - 5 + 0) / 1 + 1 = 296$ ； $H2 = (H1 - F + 2P) / S + 1 = (300 - 5 + 0) / 1 + 1 = 296$ ； $D2=K=100$ ，神经元个数为： $W2 \times H2 \times D2 = 296 \times 296 \times 100 = 8761600$ ）

6, 某一个卷积神经网络结构如下:

(i) 输入层 Input 的 RGB 图像大小是 $227 \times 227 \times 3$ 。

(ii) 第 1 层卷积层 Conv-1 是通过对输入图像用 96 个 $11 \times 11 \times 3$ 大小的滤波器通过步长(stride)为 4, 不做边缘填充(padding)得到的。

(iii) 接下来是池化层 MaxPool-1, 它用 3×3 尺寸、步长为 2 对 Conv-1 做 Max Pooling 操作。

(iv) 然后我们对图像进行边缘填充, 填充值为 2 (如原来图像大小为 7×7 时, 做填充值为 2 的填充后, 图像大小变为 11×11), 用 256 个 5×5 大小的滤波器按步长为 1, 做第二次卷积操作, 得到 Conv-2 层。

(v) 再接一个池化层 MaxPool-2, 它用 3×3 尺寸、步长为 2 做一次 Max Pooling 操作。

(vi) MaxPool-2 层输出去接一个有 4096 个神经元的全连接层 FC-1。

(vii) 再接一个全连接层 FC-2 实现对 1000 个类别的分类。

请计算: (1) 输入层到 Conv-1 层的参数量有多少? (2) 经过池化层 MaxPool-1 后的神经元是多少? (3) 经过第二次卷积操作后的图像大小为多少? (4) MaxPool-2 层到 FC-1 层的参数量是多少? (5) FC-1 层到 FC-2 层的参数量是多少?

解: 输入图像大小为 $227 \times 227 \times 3$ (即: $W_1=227, H_1=227, D_1=3$), 第一层卷积核为 11×11 (即: $F=11$), 共 96 个滤波器 (即: $K=96$), 步长为 4 (即: $S=4$), 边缘填充为 0 (即: $P=0$), 则卷积以后的图像边

长为： $((227-11+2*0)/4)+1=55$ ，大小为 $55*55$ （即 $W2=H2=55$ ），与 96 个滤波器构成特征图，所以卷积层 Conv-1 的神经元个数为 $55*55*96=290400$ ，(1)输入层到 Conv-1 层的参数量为 $F*F*D1*K+1*K$ ，即： $11*11*3*96+1*96=34944$ ；对 $55*55$ 大小的图像做第一次 Maxpooling，这时候通道数 96 保持不变，因为它用 $3*3$ 大小的尺寸以步长为 2 做 Maxpooling，则得到的图像边长为 $((55-3)/2)+1=27$ ，图像大小为 $27*27$ ，(2)经过池化层 MaxPool-1 后的神经元为 $27*27*96$ ；再做第二次卷积，此时是对 $27*27$ 大小的图像，用 $5*5$ 大小的滤波器按步长为 1，边缘填充值为 2 做卷积，滤波器个数为 256 个，所以，卷积后图像的边长为 $((27-5+2*2)/1)+1=27$ ，大小为 $27*27$ ，与 256 个滤波器构成特征图，所以卷积层 Conv-2 的神经元个数为 $27*27*256=186624$ ，(3)经过第二次卷积操作后的图像大小为 $27*27$ ，MaxPool-1 层到 Conv-2 层的参数量为： $5*5*96$ （池化层的通道数）*256（滤波器个数）+256（常数项）=614656；再经过池化层 MaxPool-2， $3*3$ 尺寸、步长为 2，则得到的图像边长为 $((27-3)/2)+1=13$ ，图像大小为 $13*13$ ，上一层的通道数是 256，所以，MaxPool-2 层的神经元个数为 $13*13*256=43264$ ；MaxPool-2 层输出去接一个有 4096 个神经元的全连接层 FC-1，所以，(4) MaxPool-2 层到 FC-1 层的参数量是 $13*13*256*4096+4096$ （常数项）=177213440；最后的输出层要对 1000 个类别进行分类，即 FC-2 层的神经元个数是 1000 个，而输入是 4096 个神经元，所以，(5) FC-1 层到 FC-2 层的参数量是 $4096*1000+1000=4097000$

7, 有训练样本集为: $D = \{(\vec{x}_1, y_1) = ((1, 1)^T, 1), (\vec{x}_2, y_2) = ((-1, -1)^T, 1), (\vec{x}_3, y_3) = ((-1, 1)^T, -1), (\vec{x}_4, y_4) = ((1, -1)^T, -1)\}$,

假设某神经网络结构为第一层有两个神经元, 第二层有三个神经元, 第三层有一个神经元, 前两层每个神经元的激活函数为ReLU (即 $x_d^{(l)} = \max(0, s_d^{(l)})$, 这里 $s_d^{(l)}$ 代表第 l 层第 d 个神经元的输入, $x_d^{(l)}$ 代表该神经元的输出), 第三层为线性输出, 即 $\hat{y} = s_1^{(3)}$ 。误差函数为: $E_{in} = \frac{1}{N} \sum_n (y_n - \hat{y}_n)^2$, 学习率为0.01。假设初始权系数矩阵定义如下:

$$\mathbf{w}_0^{(1)} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix}, \mathbf{w}_0^{(2)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}, \mathbf{w}_0^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

其中 $\mathbf{w}$ 的下标0代表迭代次数为0 (即初始状态), 上标数字分别代表第1、2、3层。要求将上述训练样本集的样本用反向传播法按顺序进行一轮训练, 写出每一次迭代时各层的权系数矩阵, 即: $t=1$ 时, 进入样本 $\vec{x}_1$, 得到 $\mathbf{w}_1^{(1)}$ 、 $\mathbf{w}_1^{(2)}$ 和 $\mathbf{w}_1^{(3)}$; $t=2$ 时, 进入样本 $\vec{x}_2$, 得到 $\mathbf{w}_2^{(1)}$ 、 $\mathbf{w}_2^{(2)}$ 和 $\mathbf{w}_2^{(3)}$; $t=3$ 时, 进入样本 $\vec{x}_3$, 得到 $\mathbf{w}_3^{(1)}$ 、 $\mathbf{w}_3^{(2)}$ 和 $\mathbf{w}_3^{(3)}$; $t=4$ 时, 进入样本 $\vec{x}_4$, 得到 $\mathbf{w}_4^{(1)}$ 、 $\mathbf{w}_4^{(2)}$ 和 $\mathbf{w}_4^{(3)}$

解:

(1) 算法步骤描述:

假设训练样本集有 N 个样本 $\{\vec{x}_1, \dots, \vec{x}_n, \dots, \vec{x}_N\}$, 每个样本有 d 维特征, 写成增广向量后是 $d+1$ 维, $\vec{x}_n = (1, x_{n1}, \dots, x_{nd})^T$, 将神经网络的输入层当第0层, 所以写为: $\vec{x}_n^{(0)} = (1, x_{n1}^{(0)}, \dots, x_{nd}^{(0)})^T$, 当 $d=2$ 时, $\vec{x}_n^{(0)} = (1, x_{n1}^{(0)}, x_{n2}^{(0)})^T$

假设第一层有两个神经元, 第二层有三个神经元, 第三层有一个神经元。

第一层、第二层和第三层的权系数矩阵分别为:

$$\mathbf{w}^{(1)} = \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix}, \quad \mathbf{w}^{(2)} = \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix}, \quad \mathbf{w}^{(3)} = \begin{pmatrix} w_{01}^{(3)} \\ w_{11}^{(3)} \\ w_{21}^{(3)} \\ w_{31}^{(3)} \end{pmatrix}$$

则第一层神经元的输入为：

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)}$$

假设第一层神经元的激活函数为ReLU，即： $x^{(1)} = \max(0, s^{(1)})$ ，则：

$$\begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix}$$

第二层神经元的输入为：

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix}$$

假设第二层神经元的激活函数为ReLU，即： $x^{(2)} = \max(0, s^{(2)})$ ，则：

$$\begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(2)}) \\ \max(0, s_2^{(2)}) \\ \max(0, s_3^{(2)}) \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix}$$

因为第三层是线性操作，即输出 $\hat{y} = s_1^{(3)}$

对于输入样本 $\vec{x}_n$ ，假设其标签为 y_n ，采用平方误差函数。即： $e_n = (y_n - \hat{y}_n)^2$

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)})$$

运用反向传播法，于是： $\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)})(x_j^{(2)})'$

对于ReLU来说，其导数为： $(x_j^{(L)})' = \llbracket s_j^{(L-1)} \geq 0 \rrbracket$

所以: $\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix}$$

继续运用反向传播法, 于是: $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$, 所以:

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到:

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

假定t表示迭代次数, η 为学习步长, 利用梯度下降法进行权系数更新:

$$\begin{aligned} \mathbf{w}_{t+1}^{(1)} &= \mathbf{w}_t^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_t^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ \mathbf{w}_{t+1}^{(2)} &= \mathbf{w}_t^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_t^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ \mathbf{w}_{t+1}^{(3)} &= \mathbf{w}_t^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_t^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} = \begin{pmatrix} w_{01}^{(3)} \\ w_{11}^{(3)} \\ w_{21}^{(3)} \\ w_{31}^{(3)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(3)} \\ x_1^{(2)} \delta_1^{(3)} \\ x_2^{(2)} \delta_1^{(3)} \\ x_3^{(2)} \delta_1^{(3)} \end{pmatrix} \end{aligned}$$

反复迭代至T次。

(2) 代入习题数据的解答流程:

t=0

$$\mathbf{w}_0^{(1)} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{w}_0^{(2)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}, \quad \mathbf{w}_0^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

t=1时，对于第一个样本 $\vec{x}_1 = (1,1)^T$ ，则第一层神经元的输入为：

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_1^{(0)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$$

第二层神经元的输入为：

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 3 \end{pmatrix} = \begin{pmatrix} 7 \\ 7 \\ 7 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 7 \\ 7 \\ 7 \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 7 \\ 7 \\ 7 \\ 7 \end{pmatrix} = 28$$

即输出 $\hat{y} = s_1^{(3)} = 28$

对于样本 $\vec{x}_1$ ，其标签为1，采用平方误差函数： $e_n = (y_n - \hat{y}_n)^2$ ，则：

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(1 - 28) = 54$$

运用反向传播法，于是：

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} 42 * 1 * 1 \\ 42 * 1 * 1 \\ 42 * 1 * 1 \end{pmatrix} = \begin{pmatrix} 42 \\ 42 \\ 42 \end{pmatrix}$$

继续运用反向传播法, 于是: $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$, 所以:

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到:

$$\begin{aligned} \vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} &= \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 42 \\ 42 \\ 42 \end{pmatrix} = \begin{pmatrix} 126 \\ 126 \end{pmatrix} \end{aligned}$$

令 $\eta = 0.01$, 利用梯度下降法进行权系数更新:

$$\begin{aligned} \mathbf{w}_1^{(1)} &= \mathbf{w}_0^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_t^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix} - 0.01 \begin{pmatrix} 126 & 126 \\ 1 * 126 & 1 * 126 \\ 1 * 126 & 1 * 126 \end{pmatrix} = \begin{pmatrix} -0.26 & -0.26 \\ -0.26 & -0.26 \\ -0.26 & -0.26 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} \mathbf{w}_1^{(2)} &= \mathbf{w}_0^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_0^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} - 0.01 \begin{pmatrix} 42 & 42 & 42 \\ 3 * 42 & 3 * 42 & 3 * 42 \\ 3 * 42 & 3 * 42 & 3 * 42 \end{pmatrix} \\ &= \begin{pmatrix} 0.58 & 0.58 & 0.58 \\ -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \end{aligned}$$

$$\begin{aligned}\mathbf{w}_1^{(3)} &= \mathbf{w}_0^{(3)} - \eta \vec{x}_n^{(2)} \overrightarrow{\delta^{(3)}}^T = \mathbf{w}_0^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} - 0.01 \begin{pmatrix} 42 \\ 7 * 42 \\ 7 * 42 \\ 7 * 42 \end{pmatrix} \\ &= \begin{pmatrix} 0.58 \\ -1.94 \\ -1.94 \\ -1.94 \end{pmatrix}\end{aligned}$$

t=2, 对于第二个样本 $\vec{x}_2 = (-1, -1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.26 \\ 0.26 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0.26 \\ 0.26 \end{pmatrix}$$

第二层神经元的输入为:

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.58 & -0.26 & -0.26 \\ 0.58 & -0.26 & -0.26 \\ 0.58 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 1 \\ 0.26 \\ 0.26 \end{pmatrix} = \begin{pmatrix} 0.44 \\ 0.44 \\ 0.44 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.44 \\ 0.44 \\ 0.44 \end{pmatrix}$$

则第三层的输入为:

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.58 & -1.94 & -1.94 & -1.94 \end{pmatrix} \begin{pmatrix} 1 \\ 0.44 \\ 0.44 \\ 0.44 \end{pmatrix} = -1.98$$

即输出 $\hat{y} = s_1^{(3)} = -1.98$

对于样本 $\vec{x}_2$, 其标签为1, 采用平方误差函数: $e_n = (y_n - \hat{y}_n)^2$, 则:

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(1 - (-1.98)) = -5.96$$

运用反向传播法, 于是:

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} -5.96 * (-1.94) * 1 \\ -5.96 * (-1.94) * 1 \\ -5.96 * (-1.94) * 1 \end{pmatrix} = \begin{pmatrix} 11.56 \\ 11.56 \\ 11.56 \end{pmatrix}$$

继续运用反向传播法，于是： $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$ ，所以：

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到：

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

$$= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 11.56 \\ 11.56 \\ 11.56 \end{pmatrix} = \begin{pmatrix} -9.02 \\ -9.02 \end{pmatrix}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\mathbf{w}_2^{(1)} = \mathbf{w}_1^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_1^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)})$$

$$= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix}$$

$$= \begin{pmatrix} -0.26 & -0.26 \\ -0.26 & -0.26 \\ -0.26 & -0.26 \end{pmatrix} - 0.01 \begin{pmatrix} -9.02 & -9.02 \\ (-1) * (-9.02) & (-1) * (-9.02) \\ (-1) * (-9.02) & (-1) * (-9.02) \end{pmatrix}$$

$$= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix}$$

$$\begin{aligned}
\mathbf{w}_2^{(2)} &= \mathbf{w}_1^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_1^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\
&= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\
&= \begin{pmatrix} 0.58 & 0.58 & 0.58 \\ -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \\
&\quad - 0.01 \begin{pmatrix} 11.56 & 11.56 & 11.56 \\ 0.26 * 11.56 & 0.26 * 11.56 & 0.26 * 11.56 \\ 0.26 * 11.56 & 0.26 * 11.56 & 0.26 * 11.56 \end{pmatrix} \\
&= \begin{pmatrix} 0.46 & 0.46 & 0.46 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_2^{(3)} &= \mathbf{w}_1^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_1^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.58 \\ -1.94 \\ -1.94 \\ -1.94 \end{pmatrix} - 0.01 \begin{pmatrix} -5.96 \\ 0.44 * (-5.96) \\ 0.44 * (-5.96) \\ 0.44 * (-5.96) \end{pmatrix} = \begin{pmatrix} 0.64 \\ -1.91 \\ -1.91 \\ -1.91 \end{pmatrix}
\end{aligned}$$

t=3, 对于第三个样本 $\vec{x}_3 = (-1, 1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.17 & -0.35 & -0.35 \\ -0.17 & -0.35 & -0.35 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -0.17 \\ -0.17 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

第二层神经元的输入为:

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.46 & -0.29 & -0.29 \\ 0.46 & -0.29 & -0.29 \\ 0.46 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.46 \\ 0.46 \\ 0.46 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.46 \\ 0.46 \\ 0.46 \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = (0.64 \quad -1.91 \quad -1.91 \quad -1.91) \begin{pmatrix} 1 \\ 0.46 \\ 0.46 \\ 0.46 \end{pmatrix} = -2.00$$

即输出 $\hat{y} = s_1^{(3)} = -2.00$

对于样本 $\vec{x}_3$ ，其标签为 -1 ，采用平方误差函数： $e_n = (y_n - \hat{y}_n)^2$ ，则：

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(-1 - (-2.00)) = -2.00$$

运用反向传播法，于是：

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即：} \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} (-2.00) * (-1.91) * 1 \\ (-2.00) * (-1.91) * 1 \\ (-2.00) * (-1.91) * 1 \end{pmatrix} = \begin{pmatrix} 3.82 \\ 3.82 \\ 3.82 \end{pmatrix}$$

继续运用反向传播法，于是： $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$ ，所以：

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到：

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 3.82 \\ 3.82 \\ 3.82 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\begin{aligned}
\mathbf{w}_3^{(1)} &= \mathbf{w}_2^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_2^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\
&= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\
&= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} - 0.01 \begin{pmatrix} 0 & 0 \\ (-1) * 0 & (-1) * 0 \\ (+1) * 0 & (+1) * 0 \end{pmatrix} \\
&= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_3^{(2)} &= \mathbf{w}_2^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_2^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\
&= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\
&= \begin{pmatrix} 0.46 & 0.46 & 0.46 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} - 0.01 \begin{pmatrix} 3.82 & 3.82 & 3.82 \\ 0 * 3.82 & 0 * 3.82 & 0 * 3.82 \\ 0 * 3.82 & 0 * 3.82 & 0 * 3.82 \end{pmatrix} \\
&= \begin{pmatrix} 0.42 & 0.42 & 0.42 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_3^{(3)} &= \mathbf{w}_2^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_2^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.64 \\ -1.91 \\ -1.91 \\ -1.91 \end{pmatrix} - 0.01 \begin{pmatrix} -2.00 \\ 0.46 * (-2.00) \\ 0.46 * (-2.00) \\ 0.46 * (-2.00) \end{pmatrix} = \begin{pmatrix} 0.66 \\ -1.90 \\ -1.90 \\ -1.90 \end{pmatrix}
\end{aligned}$$

t=4, 对于第四个样本 $\vec{x}_2 = (1, -1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.17 & -0.35 & -0.35 \\ -0.17 & -0.35 & -0.35 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -0.17 \\ -0.17 \end{pmatrix}$$

则： $\begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

第二层神经元的输入为：

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.42 & -0.29 & -0.29 \\ 0.42 & -0.29 & -0.29 \\ 0.42 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.42 \\ 0.42 \\ 0.42 \end{pmatrix}$$

则： $\begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.42 \\ 0.42 \\ 0.42 \end{pmatrix}$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.66 & -1.90 & -1.90 & -1.90 \end{pmatrix} \begin{pmatrix} 1 \\ 0.42 \\ 0.42 \\ 0.42 \end{pmatrix} = -1.73$$

即输出 $\hat{y} = s_1^{(3)} = -1.73$

对于样本 $\vec{x}_4$ ，其标签为 -1 ，采用平方误差函数： $e_n = (y_n - \hat{y}_n)^2$ ，则：

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(-1 - (-1.73)) = -1.46$$

运用反向传播法，于是：

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即： } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} (-1.46) * (-1.90) * 1 \\ (-1.46) * (-1.90) * 1 \\ (-1.46) * (-1.90) * 1 \end{pmatrix} = \begin{pmatrix} 2.77 \\ 2.77 \\ 2.77 \end{pmatrix}$$

继续运用反向传播法，于是： $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$ ，所以：

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到：

$$\begin{aligned}\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} &= \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 2.77 \\ 2.77 \\ 2.77 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}\end{aligned}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\begin{aligned}\mathbf{w}_4^{(1)} &= \mathbf{w}_3^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_3^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ &= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} - 0.01 \begin{pmatrix} 0 & 0 \\ (+1) * 0 & (+1) * 0 \\ (-1) * 0 & (-1) * 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} \\ \mathbf{w}_4^{(2)} &= \mathbf{w}_3^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_3^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 0.42 & 0.42 & 0.42 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} - 0.01 \begin{pmatrix} 2.77 & 2.77 & 2.77 \\ 0 * 2.77 & 0 * 2.77 & 0 * 2.77 \\ 0 * 2.77 & 0 * 2.77 & 0 * 2.77 \end{pmatrix} \\ &= \begin{pmatrix} 0.39 & 0.39 & 0.39 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_4^{(3)} &= \mathbf{w}_3^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_3^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.66 \\ -1.90 \\ -1.90 \\ -1.90 \end{pmatrix} - 0.01 \begin{pmatrix} -1.46 \\ 0.42 * (-1.46) \\ 0.42 * (-1.46) \\ 0.42 * (-1.46) \end{pmatrix} = \begin{pmatrix} 0.67 \\ -1.89 \\ -1.89 \\ -1.89 \end{pmatrix}
\end{aligned}$$

- (1) 集成学习 **Boosting** 算法能否实现“三个臭皮匠顶个诸葛亮”的功能？试分析原因。
同时说明要达到此功能有什么先决条件；
可以，**Boosting** 算法是将多个弱分类器组合成强分类器，多个叠加可以提高精度；
达到此功能的先决条件要求“不稳定”的分类方法，并且每个弱分类器的分类准确率大于 50%。
- (2) **AdaBoost** 算法的基本性质是能在学习过程中不断减少训练误差，请给出关于 **AdaBoost** 训练误差上界的证明。

证明：

当 $G_m(x_i) \neq y_i$ 时, $y_i f(x_i) < 0$, 因此 $e^{-y_i f(x_i)} \geq 1$

当 $G_m(x_i) = y_i$ 时, $I(G_m(x_i) \neq y_i) = 1$

从而前半部分得证。

后半部分推导要用到 Z_m 和权重的关系：

$$w_{m+1,i} = \frac{w_{mi} e^{-\alpha_m y_i G_m(x_i)}}{Z_m}, \quad i = 1, 2, \dots, N$$


$$\Rightarrow w_{mi} e^{-\alpha_m y_i G_m(x_i)} = Z_m w_{m+1,i} \quad (*)$$

由上式可得：

$$\begin{aligned} \frac{1}{N} \sum_i e^{-y_i f(x_i)} &= \frac{1}{N} \sum_i e^{-\sum_{m=1}^M \alpha_m y_i G_m(x_i)} \\ &= \sum_i w_{1i} \prod_{m=1}^M e^{-\alpha_m y_i G_m(x_i)} (w_{1i} = \frac{1}{N}) \\ &= Z_1 \sum_i w_{2i} \prod_{m=2}^M e^{-\alpha_m y_i G_m(x_i)} (\text{由式(*)可得}) \\ &= Z_1 Z_2 \sum_i w_{3i} \prod_{m=3}^M e^{-\alpha_m y_i G_m(x_i)} \\ &= \dots \\ &= \prod_{m=1}^M Z_m \end{aligned}$$

从而后半部分得证。

- (3) 分析二分类问题中 **Gini** 指数 $\text{Gini}(p)$ 、熵之半 $H(p)$ 和分类误差率之间的关系。



二类分类中基尼指数、熵之半和分类误差率的关系

基尼指数和熵之半的曲线很接近，都可以近似的代表分类误差率。当样本正负个数相等时，样本无法被某一特征所区分，三者指标达到最大值 0.5；随着样本特征对样本区分度上升，三个指标同时下降，最终同时达到最小值 0。

（4）写出决策树常见算法 ID3、C4.5 与 CART 的算法流程，说明三者之间的相同之处与不同之处。

ID3:

输入：训练数据集D，特征集A，阈值 ϵ ；

输出：决策树T。

Step1: 若D中所有实例属于同一类 c_k ，则T为单结点树，并将类 c_k 作为该结点的类标记，返回T；

Step2: 若A= $\emptyset$ ，则T为单结点树，并将D中实例数最大的类 c_k 作为该结点的类标记，返回T；

Step3: 否则，2.1.1 (3) 计算A中个特征对D的信息增益，选择信息增益最大的特征 A_k ；

Step4: 如果 A_g 的信息增益小于阈值 ϵ ，则T为单节点树，并将D中实例数最大的类 c_k 作为该结点的类标记，返回T

Step5: 否则，对 A_g 的每一种可能值 a_i ，依 $A_g=a_i$ 将D分割为若干非空子集 D_i ，将 D_i 中实例数最大的类作为标记，构建子结点，由结点及其子树构成树T，返回T；

Step6: 对第i个子节点，以 D_i 为训练集，以 $A - \{A_g\}$ 为特征集合，递归调用Step1~step5，得到子树 T_i ，返回 T_i ；

https://blog.csdn.net/mq_32172681

C4.5 算法:

C4.5 算法过程与 ID3 算法一样，区别就是将选择特征的方法由信息增益改成信息增益比。

CART 算法:

输入：训练数据集D，停止计算的条件

输出：CART决策树

根据训练数据集，从根结点开始，递归地对每个结点进行以下操作，构建二叉树：

Step1：设结点的训练数据集为D，计算现有特征对该数据集的基尼指数。此时，对每一个特征A，对其可能取的每个值a，根据样本点A=a的测试为“是”或“否”将D分割为D1和D2两部分，利用上式 $Gini(D,A)$ 来计算A=a时的基尼指数。

Step2：在所有可能的特征A以及他们所有可能的切分点a中，选择基尼指数最小的特征及其对应可能的切分点作为最有特征与最优切分点。依最优特征与最有切分点，从现结点生成两个子节点，将训练数据集依特征分配到两个子节点中去。

Step3：对两个子结点递归地调用Step1、Step2，直至满足条件。

Step4：生成CART决策树

算法停止计算的条件是节点中的样本个数小于预定阈值，或样本集的基尼指数小于预定阈值，或者没有更多特征。

https://blog.csdn.net/qz_52172661

相同之处：均为根据特征划分递归生成决策树

不同之处：三者所看指标不同，ID3 是信息增益，C4.5 是信息增益率，CART 是 Gini 指数

（5）利用所给的训练数据集 D，利用 ID3 算法根据信息增益准则选择最优特征，通过递归学习构建决策树，用以对未来的贷款申请进行分类。

训练数据集 D：贷款申请样本数据表

ID	年龄	有工作	有自己的房子	信贷情况	类别
1	青年	否	否	一般	否
2	青年	否	否	好	否
3	青年	是	否	好	是
4	青年	是	是	一般	是
5	青年	否	否	一般	否
6	中年	否	否	一般	否
7	中年	否	否	好	否
8	中年	是	是	好	是
9	中年	否	是	非常好	是
10	中年	否	是	非常好	是
11	老年	否	是	非常好	是
12	老年	否	是	好	是
13	老年	是	否	好	是
14	老年	是	否	非常好	是
15	老年	否	否	一般	否

答：首先计算经验熵 $H(D)$ 。

$$H(D) = -\frac{9}{15} \log_2 \frac{9}{15} - \frac{6}{15} \log_2 \frac{6}{15} = 0.971$$

然后计算各特征对数据集 D 的信息增益，分别以 A_1, A_2, A_3, A_4 表示年龄、有工作、有

自己的房子和信贷情况 4 个特征，则

(1)

$$\begin{aligned}
 g(D, A_1) &= H(D) - \left[\frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \right] \\
 &= 0.971 - \left[\frac{5}{15} \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) + \frac{5}{15} \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) \right] \\
 &= 0.971 - 0.888 = 0.083
 \end{aligned}$$

这里 D_1, D_2, D_3 分别是 D 中 A_1 (年龄) 取值为青年、中年和老年的样本子集。类似地，

(2)

$$\begin{aligned}
 g(D, A_2) &= H(D) - \left[\frac{5}{15} H(D_1) + \frac{10}{15} H(D_2) \right] \\
 &= 0.971 - \left[\frac{5}{15} \times 0 + \frac{10}{15} \left(-\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \right) \right] = 0.324
 \end{aligned}$$

(3)

$$\begin{aligned}
 g(D, A_3) &= 0.971 - \left[\frac{6}{15} \times 0 + \frac{9}{15} \left(-\frac{3}{9} \log_2 \frac{3}{9} - \frac{6}{9} \log_2 \frac{6}{9} \right) \right] \\
 &= 0.971 - 0.551 = 0.420
 \end{aligned}$$

(4)

$$g(D, A_4) = 0.971 - 0.608 = 0.363$$

最后，比较各特征的信息增益值。由于特征 A_3 (有自己的房子) 的信息增益值最大，所以选择特征 A_3 作为最优特征。

续：

由于特征 A_3 (有自己的房子) 的信息增益值最大，所以选择特征 A_3 作为根节点的特征。

它将训练数据集 D 划分为两个子集 D_1 (A_3 取值为“是”) 和 D_2 (A_3 取值为“否”)。由于 D_1 只有同一类的样本点，所以它成为一个叶结点，结点的类标记为“是”。


对 D_2 则需从特征 A_1 (年龄)， A_2 (有工作) 和 A_4 (信贷情况) 中选择新的特征。计算各个特征的信息增益：

$$\begin{aligned}
 g(D_2, A_1) &= H(D_2) - H(D_2 | A_1) = 0.918 - 0.667 = 0.251 \\
 g(D_2, A_2) &= H(D_2) - H(D_2 | A_2) = 0.918 \\
 g(D_2, A_4) &= H(D_2) - H(D_2 | A_4) = 0.474
 \end{aligned}$$

选择信息增益最大的特征 A_2 (有工作) 作为结点的特征。由于 A_2 有两个可能取值，从

这一结点引出两个子结点：一个对应“是”（有工作）的子结点，包含 3 个样本，它们属于同一类，所以这是一个叶结点，类标记为“是”；另一个是对应“否”（无工作）的子结点，包含 6 个样本，它们也属于同一类，所以这这也是一个叶结点，类标记为“否”。

这样生成一个如图所示的决策树。该决策树只用了两个特征（有两个内部结点）。



1. 对于两分类问题，证明最小风险贝叶斯规则可表示为

若 $l(x) = \frac{p(X|\omega_1)}{p(X|\omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(\omega_2)}{P(\omega_1)}$ ，则决策 $X \in \omega_1$ ；否则 $X \in \omega_2$ 。

解：计算条件风险

$$\begin{aligned} R(\alpha_1|x) &= \sum_{j=1}^2 \lambda_{1j} P(w_j|x) \\ &= \lambda_{11} P(w_1|x) + \lambda_{12} P(w_2|x) \end{aligned}$$

$$\begin{aligned} R(\alpha_2|x) &= \sum_{j=1}^2 \lambda_{2j} P(w_j|x) \\ &= \lambda_{21} P(w_1|x) + \lambda_{22} P(w_2|x) \end{aligned}$$

如果 $R(\alpha_1|x) < R(\alpha_2|x)$ ，则 $x \in w_1$ 。

$$\begin{aligned} \lambda_{11} P(w_1|x) + \lambda_{12} P(w_2|x) &< \lambda_{21} P(w_1|x) + \lambda_{22} P(w_2|x) \\ (\lambda_{21} - \lambda_{11}) P(w_1|x) &> (\lambda_{12} - \lambda_{22}) P(w_2|x) \\ (\lambda_{21} - \lambda_{11}) P(w_1) p(x|w_1) &> (\lambda_{12} - \lambda_{22}) P(w_2) p(x|w_2) \\ \frac{p(x|w_1)}{p(x|w_2)} &> \frac{(\lambda_{12} - \lambda_{22}) P(w_2)}{(\lambda_{21} - \lambda_{11}) P(w_1)} \end{aligned}$$

所以，如果 $\frac{p(x|w_1)}{p(x|w_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(w_2)}{(\lambda_{21} - \lambda_{11}) P(w_1)}$ ，则 $x \in w_1$ 。反之则 $x \in w_2$ 。

2. 有两类样本 ω_1 和 ω_2 ，已知先验概率 $P(\omega_1)=0.2$ 和 $P(\omega_2)=0.8$ ，类概率密度函数如下：

$$p(x|\omega_1) = \begin{cases} x & 0 \leq x < 1 \\ 2-x & 1 \leq x \leq 2 \\ 0 & \text{其他} \end{cases} \quad p(x|\omega_2) = \begin{cases} x-1 & 1 \leq x < 2 \\ 3-x & 2 \leq x \leq 3 \\ 0 & \text{其他} \end{cases}$$

(1) 求贝叶斯最小误判概率准则下的判决域，并判断样本 $x=1.5$ 属于哪一类；

(2) 求总错误概率 $P(e)$ ；

(3) 假设正确判断的损失 $\lambda_{11}=\lambda_{22}=0$ ，误判损失分别为 λ_{12} 和 λ_{21} ，若采用最小损失判决准则， λ_{12} 和 λ_{21} 满足怎样的关系时，会使上述对样本 $x=1.5$ 的判断相反？


答：

(1) 在 $1 \leq x \leq 2$ 范围内两个类别才有交集，所以只需要考虑这一段的决策域。

$$g(x) = 0.2 \times (2-x) - 0.8 \times (x-1) = 1.2 - x = 0$$

所以，决策面为 $x=1.2$ ，如下图所示。 $x < 1.2$ ，判决为第一类，否则就判决为第二类。

所以样本 $x=1.5$ 属于第 2 类。



$$(2) \quad P(e) = P(\omega_1) \int_{\Gamma_2} p(X|\omega_1) dX + P(\omega_2) \int_{\Gamma_1} p(X|\omega_2) dX = 0.08$$

$$(3) \quad \lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x) \begin{matrix} < \\ > \end{matrix} \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x), \text{ then } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

有 $\lambda_{11} = \lambda_{22} = 0$,

$\lambda_{12}P(\omega_2|x) = \lambda_{12} \times 0.8 \times (x-1) < \lambda_{21}P(\omega_1|x) = \lambda_{21} \times 0.2 \times (2-x)$, then $x \in \omega_1$, 带 入

$x=1.5$, 有 $\lambda_{12} < \frac{1}{4}\lambda_{21}$, then $x \in \omega_1$

3、已知两类问题，有 $\mu_1 = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$, $\mu_2 = \begin{bmatrix} 8 \\ 8 \end{bmatrix}$, $\Sigma_1 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, $\Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, 先验概

率为 $P(\omega_1) = 0.8$, $P(\omega_2) = 0.2$ 。

(1) 求两类的贝叶斯决策分界面。

(2) 要求根据 Bayes 决策，对样本 $x(3,3)$ 进行分类。

(1)

解 1: 公式为 $g_i(x) - g_j(x) = \frac{1}{\sigma^2}(\mu_i - \mu_j)^T x - \frac{1}{2\sigma^2}(\mu_i - \mu_j)^T(\mu_i + \mu_j) +$

$$\frac{(\mu_i - \mu_j)^T(\mu_i - \mu_j)}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)}$$

带入可得判决面方程 $-2x_1 - 2x_2 + 24 + 2\ln 2 = 0$

解 2: $W^T(x - x_0) = 0$; 其中

$$W = \mu_i - \mu_j;$$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2(\mu_i - \mu_j)}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)};$$

注意: 这里原 ppt 有误


$$g_i(x) - g_j(x) = \frac{1}{\sigma^2}(\mu_i - \mu_j)^T x - \frac{1}{2\sigma^2}(\mu_i - \mu_j)^T (\mu_i + \mu_j) + \frac{(\mu_i - \mu_j)^T (\mu_i - \mu_j)}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

$$\frac{1}{\sigma^2}(\mu_i - \mu_j)^T \left[x - \frac{1}{2}(\mu_i + \mu_j) + \frac{\sigma^2(\mu_i - \mu_j)}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} \right] = 0$$

$$W^T(x - x_0) = 0$$

其中 $W = \mu_i - \mu_j$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2(\mu_i - \mu_j)}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)}$$



这个方程确定了**决策面是通过 x_0 并正交于向量 W 的一个超平面。**

由于 $W = \mu_i - \mu_j$ 所以超平面正交于均值向量 μ_i 与 μ_j 之间的连线。

超平面向先验概率小的方向移动

107

$$\text{带入可得 } u = \frac{-4}{-4}, x_0 = \frac{6 + 0.5 \ln 2}{6 + 0.5 \ln 2};$$

(2)解。带入 (3, 3) 即可, 得 $g_i(x) - g_j(x) = 12 + 2 \ln 2$, 判为 1 类

SVM问题答疑



问题1: SVM与正则化

$$\min_{\mathbf{w}} E_{\text{aug}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}) + \frac{\lambda}{N} \mathbf{w}^T \mathbf{w}$$

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

$$\mathcal{L}(b, \mathbf{w}, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n + b))$$

	minimize	constraint
regularization	E_{in}	$\mathbf{w}^T \mathbf{w} \leq C$
SVM	$\mathbf{w}^T \mathbf{w}$	$E_{\text{in}} = 0$ [and more]

SVM (large-margin hyperplane):
 ‘weight-decay regularization’ within $E_{\text{in}} = 0$

SVM问题答疑

问题2: Hinge Loss与正则化

$$L_{SVM} = \max(0, 1 - ys)$$

$$\mathcal{L}(b, \mathbf{w}) = L_{SVM} + \lambda \mathbf{w}^T \mathbf{w}$$

$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\text{Subject to} \quad y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 \\ \text{for } n = 1, 2, \dots, N$$

$$\mathcal{L}(b, \mathbf{w}, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n + b))$$

$$\min_{\mathbf{w}} E_{\text{aug}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}) + \frac{\lambda}{N} \mathbf{w}^T \mathbf{w}$$

SVM (large-margin hyperplane):
'weight-decay regularization' within $E_{\text{in}} = 0$

SVM问题答疑

问题2: Hinge Loss与正则化

$$L_{SVM} = \max(0, 1 - ys)$$

$$\mathcal{L}(b, \mathbf{w}) = L_{SVM} + \lambda \mathbf{w}^T \mathbf{w}$$

$$\min_{\mathbf{w}} E_{\text{aug}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}) + \frac{\lambda}{N} \mathbf{w}^T \mathbf{w}$$

SVM (large-margin hyperplane):
'weight-decay regularization' within $E_{\text{in}} = 0$

$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\text{Subject to} \quad y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 \\ \text{for } n = 1, 2, \dots, N$$

$$\mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n + b))$$

```
torch.optim.SGD(net_parameters(), lr=lr_init, momentum=0.9, weight_decay=1e-2)
```


SVM问题答疑

问题3：正则化后的Hinge Loss与SVM的二次规划求解

$$L_{SVM} = \max(0, 1 - ys)$$

$$\mathcal{L}(b, \mathbf{w}) = L_{SVM} + \lambda \mathbf{w}^T \mathbf{w}$$

$$\min_{\alpha} \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n$$

$$\text{Subject to} \quad \sum_{n=1}^N \alpha_n y_n = 0$$

$$\alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N$$

$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$


$$\text{Subject to} \quad y_n (\mathbf{w}^T \mathbf{x}_n + b) \geq 1$$

for $n = 1, 2, \dots, N$


$$\mathcal{L}(b, \mathbf{w}, \alpha) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n + b))$$

$$\text{SVM} \equiv \min_{b, \mathbf{w}} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, \mathbf{w}, \alpha) \right)$$

SVM问题答疑



问题4: Hard Margin SVM与Soft Margin SVM



$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{n=1}^N \zeta_n$$

$$\text{Subject to} \quad y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 - \zeta_n, \zeta_n \geq 0 \\ \text{for } n = 1, 2, \dots, N$$

$$\mathcal{L}(b, \mathbf{w}, \zeta, \alpha, \beta) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{n=1}^N \zeta_n + \\ \sum_{n=1}^N \alpha_n (1 - \zeta_n - y_n(\mathbf{w}^T \mathbf{z}_n + b)) + \sum_{n=1}^N \beta_n (-\zeta_n)$$

$$\text{SVM} \equiv \min_{b, \mathbf{w}, \zeta} \left(\max_{\text{all } \alpha_n, \beta_n \geq 0} \mathcal{L}(b, \mathbf{w}, \zeta, \alpha, \beta) \right)$$


$$\min_{\alpha} \quad \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad \sum_{n=1}^N \alpha_n y_n = 0 \\ 0 \leq \alpha_n \leq C, \text{ for } n = 1, 2, \dots, N$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{\text{SV}} \alpha_n y_n \mathbf{z}_n$$

$$\beta_n = C - \alpha_n, \text{ for } n = 1, 2, \dots, N$$

SVM问题答疑

问题4: Hard Margin SVM与Soft Margin SVM



$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{n=1}^N \zeta_n$$

non-SV: $\alpha_n = 0, \zeta_n = 0$

■ free-SV: $0 < \alpha_n < C, \zeta_n = 0$

▲ bounded-SV: $\alpha_n = C, \zeta_n \neq 0$

Subject to $y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 - \zeta_n, \zeta_n \geq 0$
for $n = 1, 2, \dots, N$

$$\mathcal{L}(b, \mathbf{w}, \zeta, \alpha, \beta) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{n=1}^N \zeta_n + \sum_{n=1}^N \alpha_n (1 - \zeta_n - y_n(\mathbf{w}^T \mathbf{z}_n + b)) + \sum_{n=1}^N \beta_n (-\zeta_n)$$

$$\text{SVM} \equiv \min_{b, \mathbf{w}, \zeta} \left(\max_{\text{all } \alpha_n, \beta_n \geq 0} \mathcal{L}(b, \mathbf{w}, \zeta, \alpha, \beta) \right)$$

$$\min_{\alpha} \quad \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n$$

Subject to $\sum_{n=1}^N \alpha_n y_n = 0$

$$0 \leq \alpha_n \leq C, \text{ for } n = 1, 2, \dots, N$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{\text{SV}} \alpha_n y_n \mathbf{z}_n$$

$$\beta_n = C - \alpha_n, \text{ for } n = 1, 2, \dots, N$$

SVM问题答疑

问题5: SVM与过拟合

$$\min_{\alpha} \quad \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n$$


$$\text{Subject to} \quad \sum_{n=1}^N \alpha_n y_n = 0$$

$$0 \leq \alpha_n \leq C, \text{ for } n = 1, 2, \dots, N$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{\text{SV}} \alpha_n y_n \mathbf{z}_n$$

$$\beta_n = C - \alpha_n, \text{ for } n = 1, 2, \dots, N$$

SVM也会发生过拟合



横轴: C; 纵轴: γ